Projet d'Analyse de Données

Étude et Applications des Modèles de Régression Linéaire

Rapport de Projet

November 3, 2026

Contents

Introduction **2**

1 Régression Linéaire Simple : Rappels Théoriques **2**
- 1.1 Le Modèle Mathématique . . . 2
- 1.2 Estimation par les Moindres Carrés . . . 2
- 1.3 Validation du Modèle . . . 3
- 1.4 Vérification des Hypothèses . . . 3

2 Application sur le Dataset A **3**
- 2.1 Visualisation et Ajustement du Modèle . . . 3
- 2.2 Qualité de l'ajustement et Significativité . . . 3
- 2.3 Validation des Hypothèses sur le bruit . . . 3
- 2.4 Calcule de l'espérance . . . 4
- 2.5 Prédiction et Intervalles . . . 5

3 Analyse et Interprétation du Modèle(dataset B) **6**

4 Analyse et Interprétation du Modèle (Jeu de données C) **9**

5 Analyse de la variance à un facteur: Jeu de données H **34**
- 5.1 Exploration Visuelle . . . 34
- 5.2 Test d'influence globale . . . 35
- 5.3 Estimation des effets spécifiques . . . 35
- 5.4 Vérification des hypothèses du modèle . . . 35
- 5.5 Analyse de la variance à un facteur: Jeu de données I . . . 37
- 5.6 Exploration Visuelle . . . 37
- 5.7 Test d'influence globale . . . 37
- 5.8 Estimation des effets spécifiques . . . 38
- 5.9 Vérification des hypothèses du modèle . . . 38

6 Généralisation : Régression Polynomiale **39**
- 6.1 Exploration Visuelle . . . 39
- 6.2 Ajustement du modèle et Résultats . . . 40
- 6.3 Vérification des hypothèses sur les résidus . . . 41

Introduction

Ce rapport présente une étude approfondie des modèles de régression linéaire et de leurs applications. L'objectif est de comprendre comment modéliser la relation entre une variable réponse et une ou plusieurs variables explicatives à travers différents cadres d'étude.

Le rapport est structuré de la manière suivante :

1. La régression linéaire simple.
2. La régression linéaire multiple.
3. Les méthodes de sélection de variables.
4. La régression linéaire pour des variables qualitatives (Analyse de la variance).
5. La régression polynomiale.

Pour chaque méthode, un rappel théorique sera suivi d'une application pratique sur un jeu de données spécifique afin d'en interpréter les résultats.

1 Régression Linéaire Simple : Rappels Théoriques

La régression linéaire simple est le modèle le plus fondamental. Son objectif est d'expliquer une variable réponse quantitative Y à l'aide d'une unique variable explicative quantitative X.

1.1 Le Modèle Mathématique

À partir d'un échantillon de n observations $\{(x_i, y_i)\}_{i=1,\dots,n}$, le modèle postule l'existence d'une relation affine perturbée par un aléa (le bruit). Le modèle s'écrit :

$$Y_i = ax_i + b + \epsilon_i \quad \forall i \in \{1, \dots, n\} \tag{1}$$

où :

- a et b sont les paramètres inconnus du modèle (respectivement la pente et l'ordonnée à l'origine).
- ϵ_i représente le terme d'erreur ou le bruit pour l'individu i.

Pour que le modèle soit valide et que l'on puisse réaliser des tests statistiques, nous posons les hypothèses suivantes sur le bruit ϵ_i :

- **Espérance nulle** : $E[\epsilon_i] = 0$ (le modèle est correct en moyenne).
- **Homoscédasticité** : $V[\epsilon_i] = \sigma^2$ (la variance de l'erreur est constante).
- **Indépendance** : $cov(\epsilon_i, \epsilon_k) = 0$ pour $i \neq k$.
- **Gaussianité** (souvent requise pour les tests) : Les ϵ_i suivent une loi Normale $\mathcal{N}(0, \sigma^2)$.

1.2 Estimation par les Moindres Carrés

Le principe des moindres carrés consiste à trouver les estimateurs $\hat{a}_n$ et $\hat{b}_n$ qui minimisent le risque empirique (la somme des carrés des écarts entre les valeurs observées et les valeurs prédites par la droite).

Les solutions analytiques de ce problème de minimisation sont :

$$\hat{a}_n = \frac{\sum_{i=1}^n (x_i - \bar{x}_n)(Y_i - \bar{Y}_n)}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \tag{2}$$

$$\hat{b}_n = \bar{Y}_n - \hat{a}_n \bar{x}_n \tag{3}$$

où $\bar{x}_n$ et $\bar{Y}_n$ sont les moyennes empiriques. La prédiction pour un individu i est alors donnée par $\hat{Y}_i = \hat{a}_n x_i + \hat{b}_n$. La variance du bruit σ^2 est estimée de manière sans biais par $\hat{\sigma}_n^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$.

1.3 Validation du Modèle

Une fois le modèle estimé, il est indispensable de vérifier sa pertinence.

Le coefficient de détermination (R^2) Il mesure la proportion de la variance de Y expliquée par le modèle. Il est défini par :

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y}_n)^2} \tag{4}$$

Un R^2 proche de 1 indique un excellent ajustement du modèle aux données.

Le test de significativité de la pente (a) Pour s'assurer que la variable X apporte réellement une information sur Y, on teste l'hypothèse nulle $\mathcal{H}_0 : a = 0$ contre l'alternative $\mathcal{H}_1 : a \neq 0$. Sous l'hypothèse de gaussianité du bruit, on utilise une statistique de test T_a qui suit une loi de Student à $n-2$ degrés de liberté. En pratique, si la p-valeur associée est inférieure au seuil de risque (souvent 5%), on rejette $\mathcal{H}_0$ et on conclut que la variable est significative.

1.4 Vérification des Hypothèses

La validité des tests statistiques repose fortement sur l'hypothèse de gaussianité du bruit. Puisque le bruit réel est inobservable, nous étudions les **résidus**. Pour vérifier leur normalité, nous pouvons utiliser :

- **Le graphique Quantile-Quantile (Q-Q plot)** : Les points doivent s'aligner le long de la première bissectrice.
- **Le test de Kolmogorov-Smirnov** : Un test formel d'adéquation de distribution dont l'hypothèse nulle $\mathcal{H}_0$ suppose que les résidus suivent la loi théorique (Loi de Student dans notre cas exact).

2 Application sur le Dataset A

Cette section présente l'étude empirique menée sur notre jeu de données A (constitué de $n = 500$ observations), en appliquant la méthodologie de la régression linéaire simple.

2.1 Visualisation et Ajustement du Modèle

L'analyse visuelle du nuage de points brut confirme graphiquement l'existence d'une forte relation linéaire croissante entre la variable explicative X et la variable réponse Y. L'ajustement de notre modèle par la méthode des moindres carrés (MCO) nous donne l'équation de régression empirique suivante :

$$\hat{Y}_i = 1,22 \cdot x_i - 2,48$$

2.2 Qualité de l'ajustement et Significativité

Pour évaluer la pertinence de ce modèle, nous nous appuyons sur deux indicateurs majeurs :

- **Le coefficient de détermination (R^2)** : Il s'élève à $0,9821$. Cela signifie que **98,21 % de la variance de la variable réponse est expliquée** par notre modèle. C'est un ajustement d'excellente qualité.
- **Le test de la pente (a)** : La p-valeur associée à la pente est infiniment petite ($< 2 \cdot 10^{-16}$). Étant largement inférieure au seuil de $0,05$, nous rejetons fermement l'hypothèse nulle ($a = 0$). La variable X a donc un impact réel et hautement significatif sur Y.

2.3 Validation des Hypothèses sur le bruit

Pour que nos conclusions et futures prédictions soient fiables, nous devons valider les hypothèses théoriques portant sur les résidus du modèle :

- **Normalité** : Le diagramme Quantile-Quantile (Q-Q Plot) montre un alignement quasi-parfait des résidus sur la première bissectrice. Le test statistique de Kolmogorov-Smirnov confirme ce constat visuel avec une p-valeur de $0,7798$ (largement supérieure à $0,05$). L'hypothèse de normalité est donc validée.

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -2.48335    0.31122  -7.979 1.02e-14 ***
X_vec        1.22074    0.00738 165.416  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 6.371 on 498 degrees of freedom
Multiple R-squared:  0.9821,    Adjusted R-squared:  0.9821
F-statistic: 2.736e+04 on 1 and 498 DF,  p-value: < 2.2e-16

> |
```

Figure 1: Le coefficient de détermination R^2 et p-valeur

analyse de la covariance

D'après notre graphique , on a la covariance est nulle

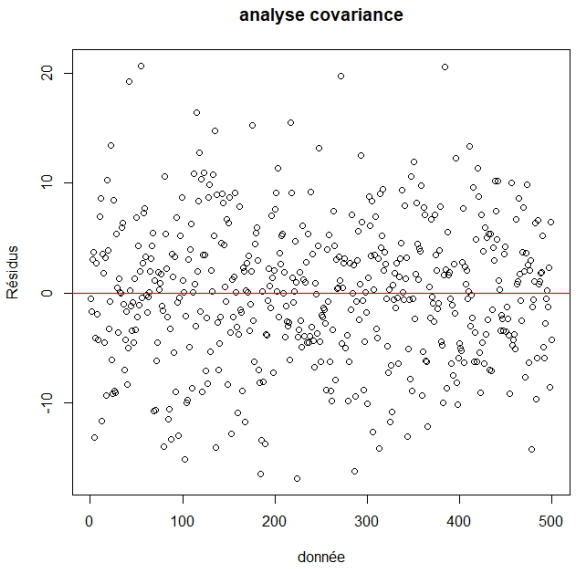


Figure 2:

2.4 Calcule de l'espérance

on ici notre espérance est $<$ 10e-16 le zeros numérique donc l'espérance est nulle.

```
> print(mean(L1$residuals))
[1] -5.629178e-18
```

Figure 3:

```
        Asymptotic one-sample Kolmogorov-Smirnov test

data:  residus_studentises_manuels
D = 0.029419, p-value = 0.7798
alternative hypothesis: two-sided
```

Figure 4: Le test statistique de Kolmogorov

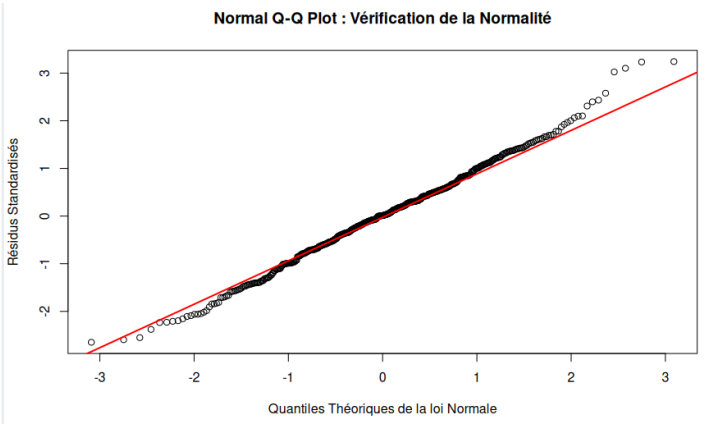


Figure 5: Q-Q plot

Homoscédasticité : variance constante

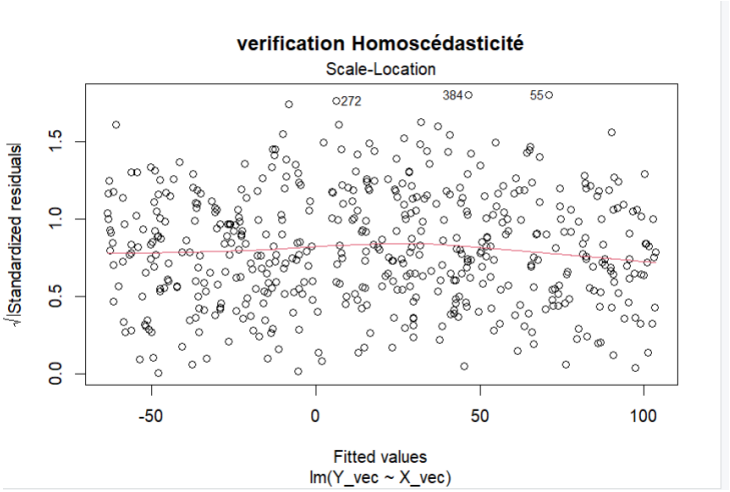


Figure 6: Test Homoscédasticité

2.5 Prédiction et Intervalles

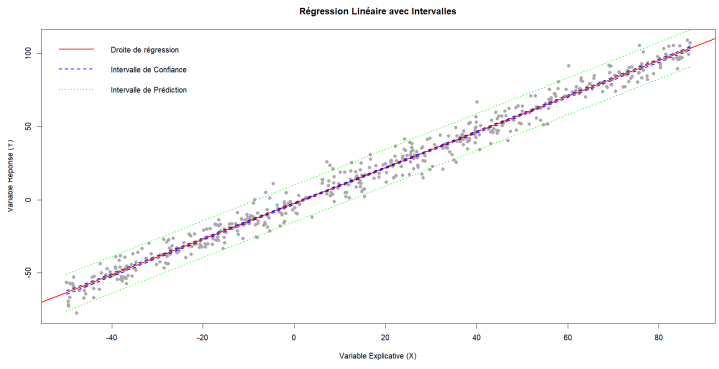


Figure 7: Modèle linéaire ajusté avec bandes de confiance (bleu) et de prévision (vert) à 95 %.

La Figure 7 synthétise notre travail : elle illustre la droite de régression entourée de ses intervalles de confiance et de prédiction à 95 %. La quasi-totalité des points se trouve naturellement contenue à l'intérieur du fuseau de prédiction, confirmant visuellement la fiabilité et la précision de notre étude sur ce jeu de données.

3 Analyse et Interprétation du Modèle(dataset B)

1. Qualité globale de l'ajustement linéaire

Le résumé statistique de la fonction `lm()` évalue la pertinence de la **droite de régression** :

- La p-valeur associée au paramètre a (la pente de X) est $< 2 \cdot 10^{-16}$. Étant strictement inférieure au seuil de risque $\alpha = 0,05$, on rejette fermement l'**hypothèse nulle** $\mathcal{H}_0$ $(a = 0)$.
- Le **coefficient de détermination** R^2 s'élève à $0,9696$. La droite capte près de 97% de la variance des données.

```
> L1 <- lm(Y_vec ~ X_vec)
> summary(L1)

Call:
lm(formula = Y_vec ~ X_vec)

Residuals:
    Min      1Q  Median      3Q     Max
-13.825  -9.168  -3.744   4.778  86.780

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 11.150633   0.642558   17.35   <2e-16 ***
X_vec        1.228963   0.009961  123.38   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.7 on 478 degrees of freedom
Multiple R-squared:  0.9696,    Adjusted R-squared:  0.9695
F-statistic: 1.522e+04 on 1 and 478 DF,  p-value: < 2.2e-16
```

Figure 8: Résumé statistique du modèle et Test de Fisher

2. Hypothèse de Normalité du bruit (Rejetée)

Géneralement ,la régression suppose que les **erreurs** ϵ_i suivent une **distribution normale**.

- **Le test de Kolmogorov-Smirnov :** Le calcul renvoie une p-valeur de $1,314 \cdot 10^{-10}$. Cette valeur est très largement inférieure à $0,05$, donc on rejette l'hypothèse de normalité.
- **Visualisation du QQ-plot:** le graphique du QQ-plot valide le rejet du modèle, car on a une distribution très asymétrique avec la bisectrice.

```
        Asymptotic one-sample Kolmogorov-Smirnov test

data:  residus_studentises_manuels
D = 0.15628, p-value = 1.314e-10
alternative hypothesis: two-sided
```

Figure 9: Résultat du test de Kolmogorov-Smirnov dans la console

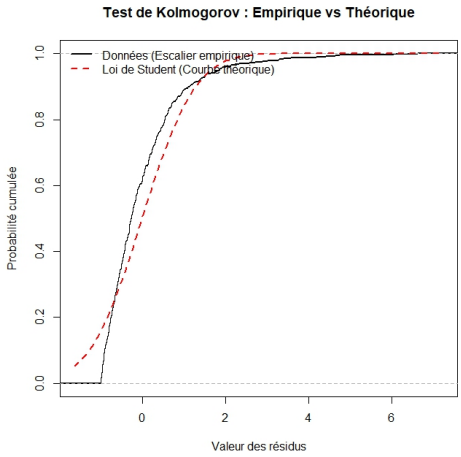


Figure 10: Test de Kolmogorov : Fonction de répartition Empirique vs Théorique

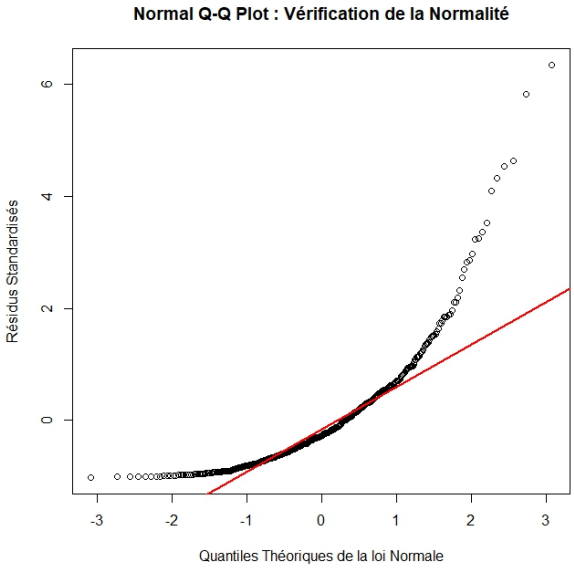


Figure 11: QQ-plot : Vérification visuelle de la normalité des résidus

3. Vérification des hypothèses fondamentales sur les résidus(Espérance, Variance et la Covariance)

- On a l'espérance des residus est -3.830432e-18<10e-16 le zeros numérique , l'hypothèse d'espérance nulle est verifié.

```
> print(mean(L1$residuals))
[1] -3.830432e-16
```

Figure 12: Vérification de l'espérance

- D'après le graphique, l'hypothèse d'indépendance des residus est validé.

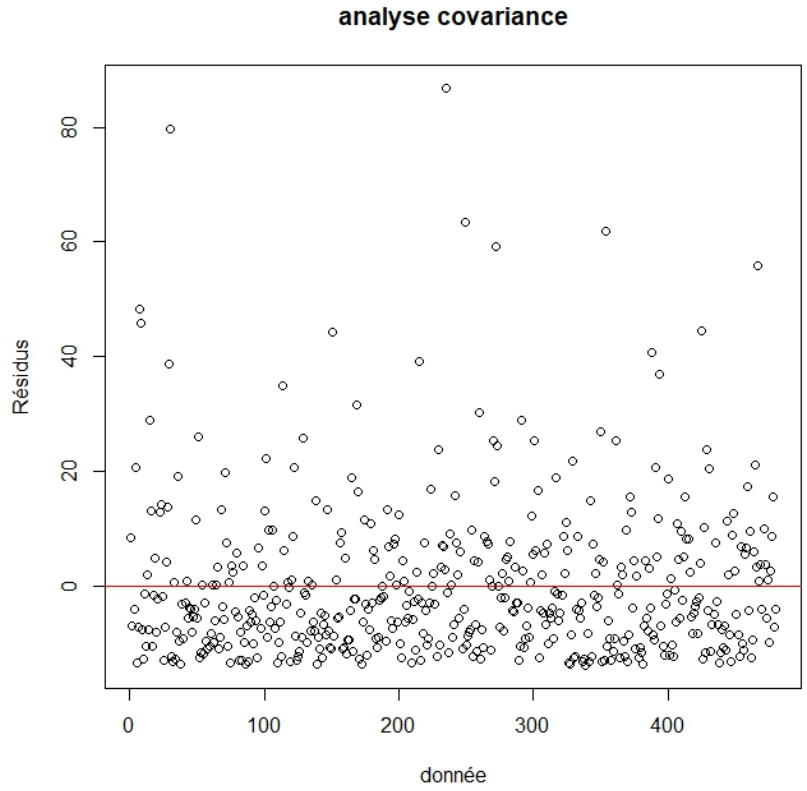


Figure 13: Vérification de l'hypothèse d'indépendance des erreurs

- La courbe de tendance rouge est relativement horizontale, ce qui valide globalement le principe d'une variance constante sur la majorité des données.

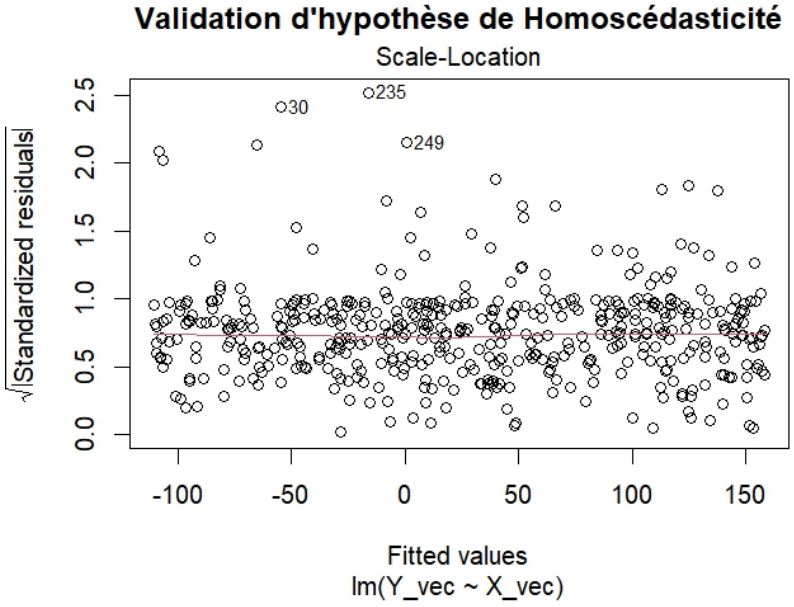


Figure 14: Vérification de l'Homoscédasticité

4. Conséquence sur les Intervalles de Prédiction

- La formule théorique utilisée pour calculer l'intervalle de prédiction à 95% repose intégralement sur l'hypothèse que le bruit suit une loi de Student/Normale.
- Puisque cette hypothèse a été invalidée à l'étape 2,l'intervalle calculé n'englobe pas les points aux extremités,car notre intervalle de prediction ne prend pas le 95% des données ici.

4 Analyse et Interprétation du Modèle (Jeu de données C)

1. Qualité globale de l'ajustement linéaire

Le résumé statistique de la fonction `lm()` évalue la pertinence de la **droite de régression** :

- La p-valeur associée au paramètre a (la pente) est $< 2 \cdot 10^{-16}$. Étant strictement inférieure au seuil de risque $\alpha = 0,05$, on rejette fermement l'**hypothèse nulle** $\mathcal{H}_0$ ($a = 0$).
- Le **coefficient de détermination** R^2 est de $0,979$. La droite explique près de 98% de la variance des données. D'un point de vue purement géométrique, la droite suit parfaitement la tendance du nuage de points.

```
> summary(L1)

Call:
lm(formula = Y_vec ~ X_vec)

Residuals:
     Min       1Q   Median       3Q      Max
-20.1461  -2.2293  -0.1973   3.7831  25.4706

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -3.8525     1.1808  -3.263  0.00204 **
X_vec         2.9509     0.0624  47.289  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 7.974 on 48 degrees of freedom
Multiple R-squared:  0.979,     Adjusted R-squared:  0.9785
F-statistic:  2236 on 1 and 48 DF,  p-value: < 2.2e-16
```

Figure 15: Résumé statistique du modèle et Test de Fisher

2. Hypothèse de Normalité du bruit (Validée de justesse, mais fragile)

L'analyse de la **distribution normale** des erreurs révèle ici une limite intéressante des tests statistiques face aux petits échantillons ($n = 50$).

- **Le test de Kolmogorov-Smirnov :** La p-valeur obtenue est de $0,0568$.Ce qui est proche du seuil de $0,05$, l'hypothèse de normalité n'est pas rejetée. Le modèle s'ajuste très bien au centre de la distribution, ce qui suffit à valider le test mathématiquement.
- **visualisation du Q-Q plot :** Malgré la réussite du test, le graphique révèle des écarts prononcés aux extrémités. Cette nuance s'explique par la faible sensibilité du test de Kolmogorov aux valeurs extrêmes, d'autant plus sur un petit échantillon ($n = 50$).

```
        Exact one-sample Kolmogorov-Smirnov test

data:  residus_studentises_manuels
D = 0.1851, p-value = 0.05678
alternative hypothesis: two-sided
```

Figure 16: Résultat du test de Kolmogorov-Smirnov dans la console

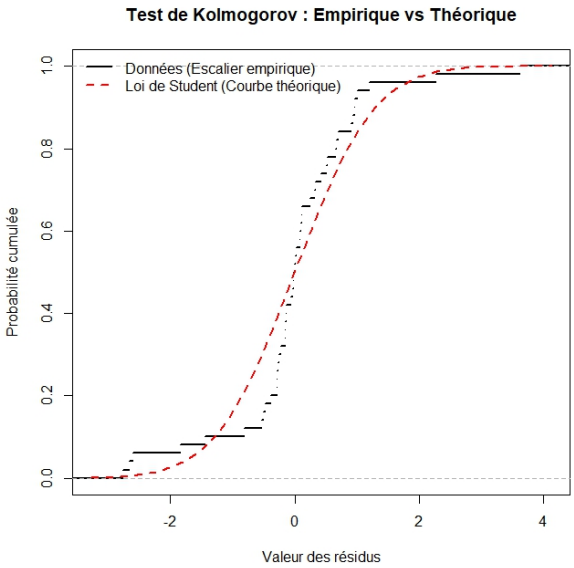


Figure 17: Test de Kolmogorov : L'écart maximal (D) n'est pas suffisant pour rejeter le test

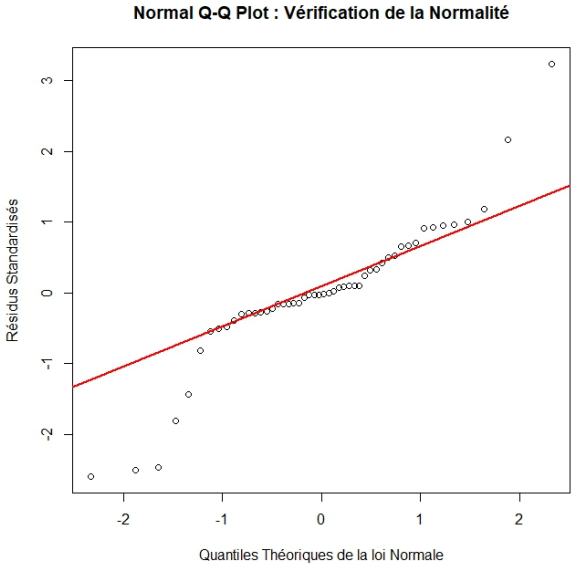


Figure 18: QQ-plot : Déviations visibles aux extrémités malgré un test valide

3. Vérification des hypothèses fondamentales sur les résidus(Espérance, Variance et la Covariance)

Le graphique met en évidence un problème structurel majeur sur la **variance du bruit**.

- On a l'espérance des residus est 1.052983e-18<10e-16 le zeros numérique , l'hypothèse d'espérance nulle est verifié.

```
> print(mean(L1$residuals))
[1] 1.052983e-16
```

Figure 19: Vérification de l'espérance

- D'après le graphique, l'hypothèse d'indépendance des residus est validé.

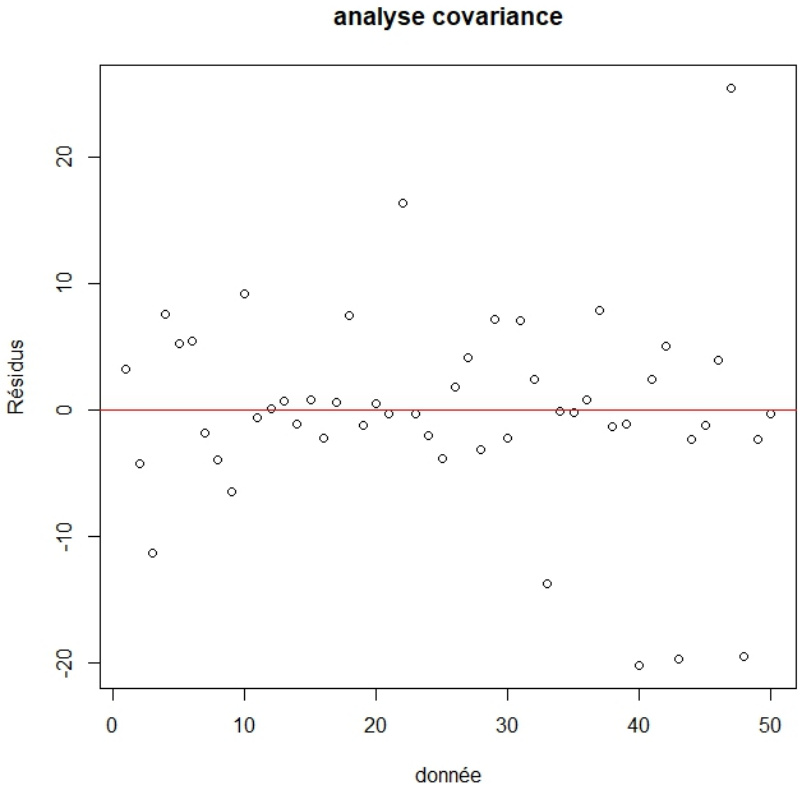


Figure 20: Vérification de l'hypothèse d'indépendance des erreurs

- **Vérification de l'homoscédasticité :** Le graphique révèle un problème d'**hétéroscédasticité** (variance non constante du bruit). L'éparpillement des résidus augmente proportionnellement avec les valeurs prédites. Cet effet d'échelle indique simplement que la marge d'erreur absolue du modèle s'amplifie naturellement pour les grandes valeurs de X.

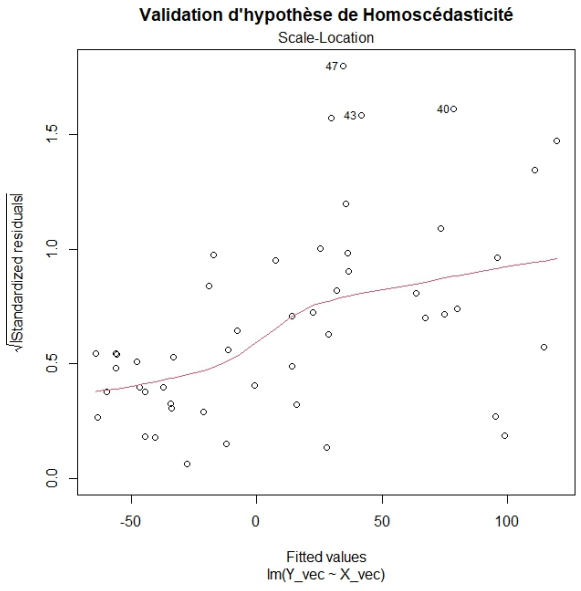


Figure 21: La variance augmente avec les valeurs (Hétéroscédasticité)

4. Conséquence sur les Intervalles de Prédiction

On observe visuellement qu'environ 4 points sur 50 (soit 8%) sortent de l'**intervalle de prédiction** à 95%, au lieu des 5% théoriques (qui correspondraient à $2,5$ points). Ce débordement est la conséquence mathématique directe de l'hétéroscédasticité observée précédemment.

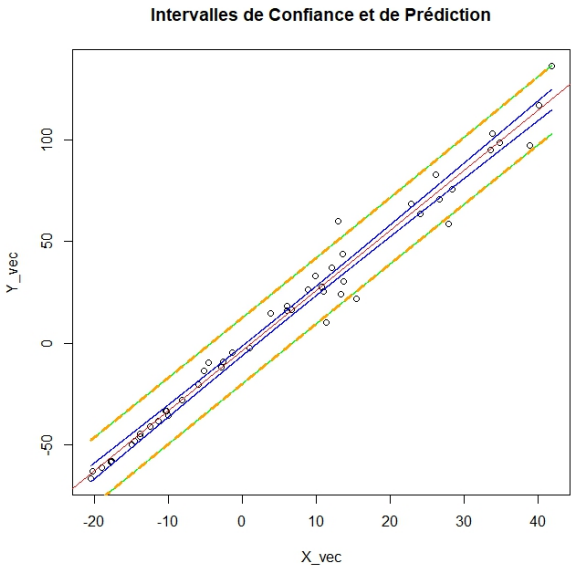


Figure 22: L'intervalle de prédiction à largeur constante peine à contenir les valeurs élevées

Conclusion sur la validité du modèle

Bien que le modèle possède un R^2 très élevé et qu'il passe de justesse le test de normalité de Kolmogorov, il est invalidé par la présence d'hétéroscédasticité. La non-constance de la variance rend l'intervalle de prédiction inadaptée a la réalité de nos données.

Introduction : Analyse visuelle globale(dataset D)

L'observation du nuage de points complet du jeu de données révèle un comportement linéaire par morceaux .une phase strictement croissante, suivie d'une phase strictement décroissante.

Afin de modéliser correctement ce phénomène, nous avons scindé les données en deux pour appliquer une régression linéaire simple indépendante sur chaque phase.

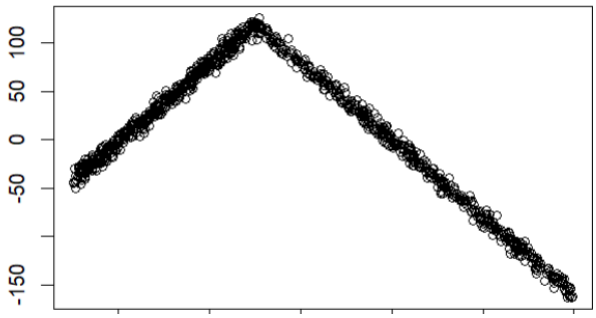


Figure 23: Nuage de points global illustrant la rupture de tendance

Analyse de la phase croissante ($X \leq 32$)

1. Qualité de l'ajustement

L'ajustement de la droite sur cette première moitié des données est statistiquement excellent :

- La p-valeur du test de Fisher est de $< 2,2 \cdot 10^{-16}$. Le modèle est très largement significatif.
- Le coefficient de détermination R^2 s'élève à $0,9881$. La droite de régression capte et explique près de 99% de la variance des données.

```
Call:
lm(formula = Y_vec ~ X_vec)

Residuals:
     Min       1Q   Median       3Q      Max
-15.8926  -3.2089   0.1728   3.5478  15.3874

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.75747    0.30562   -5.75 1.53e-08 ***
X_vec        3.98634    0.01937  205.76  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 5.227 on 511 degrees of freedom
Multiple R-squared:  0.9881,    Adjusted R-squared:  0.9881
F-statistic: 4.234e+04 on 1 and 511 DF,  p-value: < 2.2e-16
```

Figure 24: Résumé statistique du modèle (Phase Croissante)

2. Validation de la Normalité

Le bruit suit ici un comportement idéal.

- Le test de Kolmogorov-Smirnov renvoie une p-valeur de $0,3342$. Étant supérieure au seuil de $0,05$, l'hypothèse de normalité des résidus est validée.
- **visualisation de QQ-plot:** Le QQ-Plot est parfait. Les points sont alignés parfaitement sur la bisectrice, confirmant l'absence de valeurs aberrantes extrêmes.

```
--- Test de Kolmogorov (X <= 32) ---
> print(test_kolmogorov)

        Asymptotic one-sample Kolmogorov-Smirnov test

data:  residus_studentises_manuels
D = 0.041705, p-value = 0.3342
alternative hypothesis: two-sided
```

Figure 25: Résultat du test de Kolmogorov (Phase Croissante)

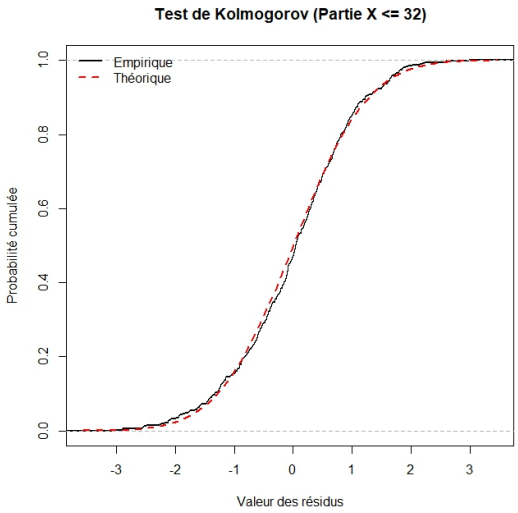


Figure 26: Fonction de répartition

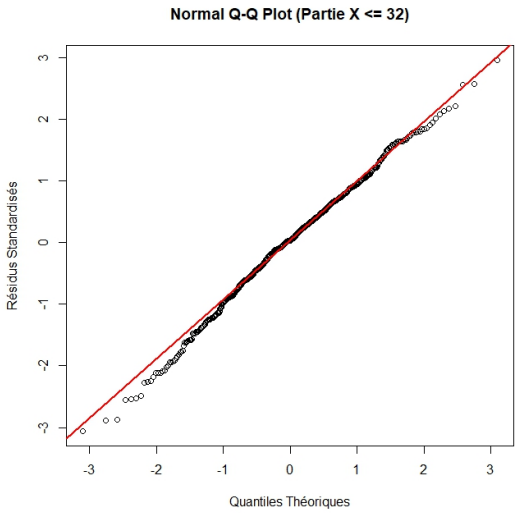


Figure 27: QQ-Plot

3. Vérification des hypothèses fondamentales sur les résidus(Espérance, Variance et la Covariance)

On a l'espérance des residus est 4.480363e-16<10e-16 le zeros numérique , l'hypothèse d'espérance nulle est verifié.

```
> mean(residuals(L1_gauche))
[1] 4.480363e-16
```

Figure 28: Vérification de l'espérance

- D'après le graphique, l'hypothèse d'indépendance des residus est validé.

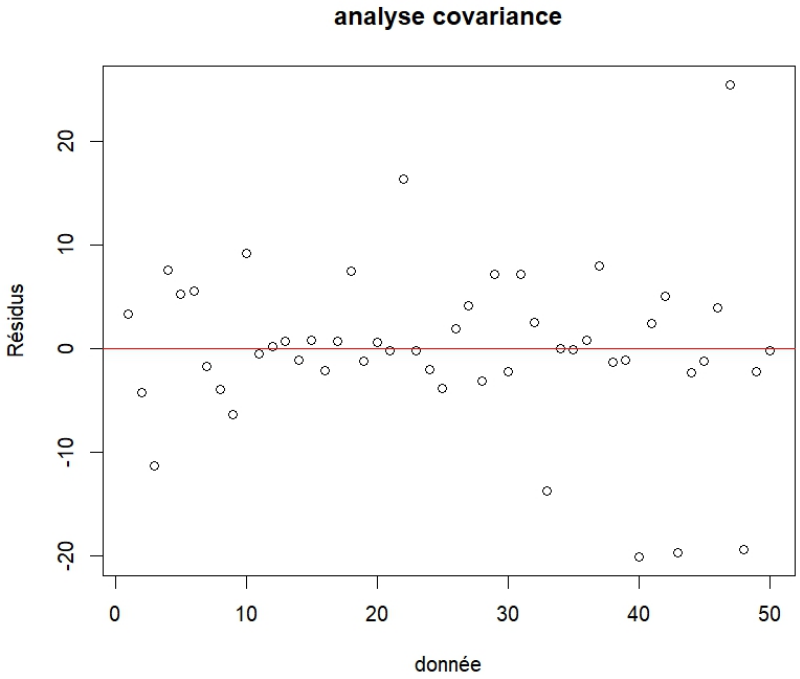


Figure 29: Vérification de l'hypothèse d'indépendance des erreurs

Le graphique montre un nuage de points dispersé de manière homogène. La ligne de tendance rouge est globalement plate et horizontale. La variance du bruit ne s'amplifie pas avec l'augmentation de X : l'hypothèse de variance constante est validée.

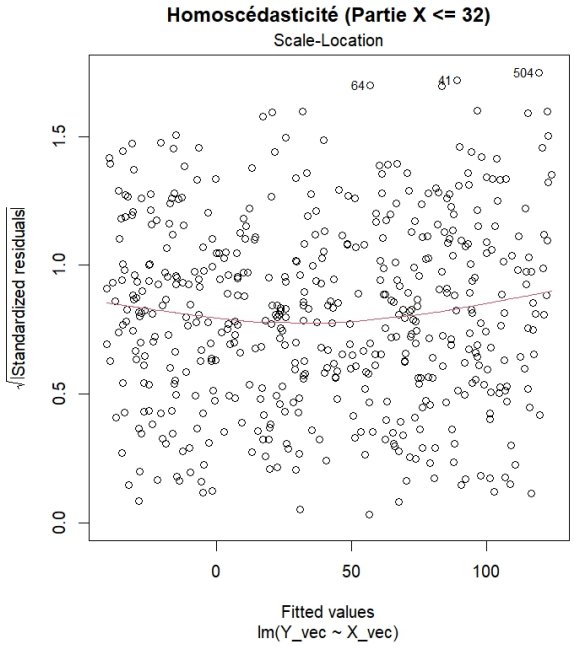


Figure 30: Scale-Location : Validation de l'Homoscédasticité

4. Intervalles de Prédiction

Puisque toutes les hypothèses mathématiques du modèle sont validées, nos calculs d'intervalles sont fiables. Visuellement, les limites de l'intervalle de prédiction à 95% encadrent parfaitement le nuage de

points, avec une largeur constante adaptée.

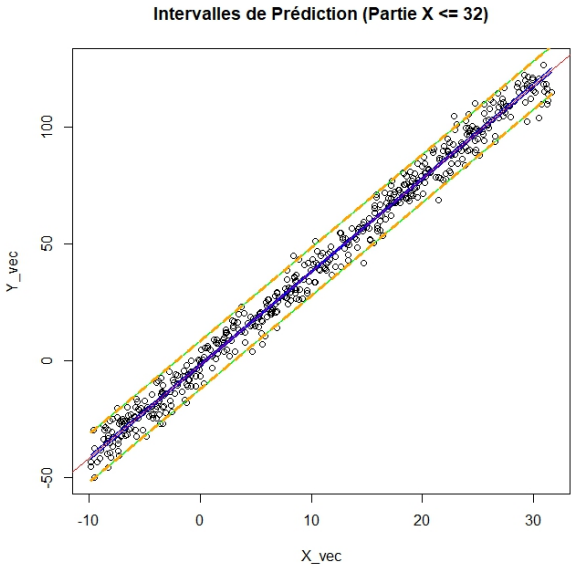


Figure 31: Intervalles de confiance et de prédiction (Phase Croissante)

Analyse de la phase décroissante ($X > 32$)

1. Qualité de l'ajustement

Tout comme pour la première phase, l'ajustement de la droite sur cette seconde moitié est excellent :

- La p-valeur du test de Fisher est de $< 2,2 \cdot 10^{-16}$.
- Le coefficient de détermination R^2 s'élève à $0,9959$. La droite explique plus de $99,5\%$ de la variance des données lors de cette descente.

```
Call:
lm(formula = Y_vec ~ X_vec)

Residuals:
     Min       1Q   Median       3Q      Max
-13.5280  -3.1010  -0.0113   2.7085  14.3899

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 239.62783    0.80215   298.7   <2e-16 ***
X_vec        -3.99545    0.01162  -343.8   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 4.831 on 485 degrees of freedom
Multiple R-squared:  0.9959,    Adjusted R-squared:  0.9959
F-statistic: 1.182e+05 on 1 and 485 DF,  p-value: < 2.2e-16
```

Figure 32: Résumé statistique du modèle (Phase Décroissante)

2. Validation de la Normalité

Le comportement du bruit reste idéal sur cette portion.

- Le test de Kolmogorov-Smirnov renvoie une p-valeur de $0,3366$. L'hypothèse de normalité est largement validée.
- **visualisation du QQ-plot** Les points sont alignées parfaitement sur la bisectrice,donc l'hypothèse de la normalité est valide.

```
--- Test de Kolmogorov (X > 32) ---
> print(test_kolmogorov)

        Asymptotic one-sample Kolmogorov-Smirnov test

data:  residus_studentises_manuels
D = 0.042717, p-value = 0.3366
alternative hypothesis: two-sided

>
```

Figure 33: Résultat du test de Kolmogorov (Phase Décroissante)

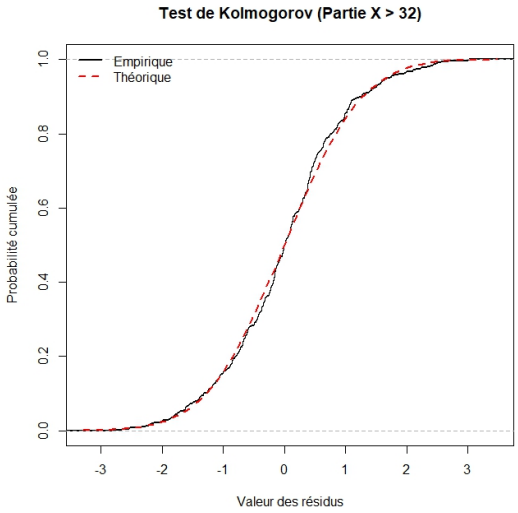


Figure 34: Fonction de répartition

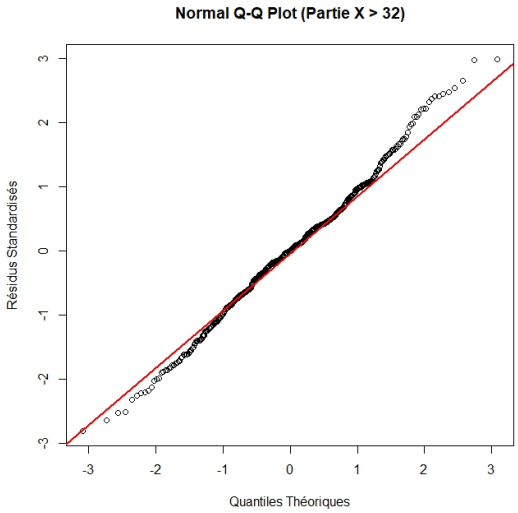


Figure 35: QQ-Plot

3. Vérification des hypothèses fondamentales sur les résidus(Espérance, Variance et la Covariance)

On a l'espérance des residus est 3.414609e-16<10e-16 le zeros numérique , l'hypothèse d'espérance nulle est verifié.

```
> print(mean(residuals(LI_droite)))
[1] 3.414609e-16
```

Figure 36: Vérification de l'espérance

- D'après le graphique, l'hypothèse d'indépendance des residus est validé.

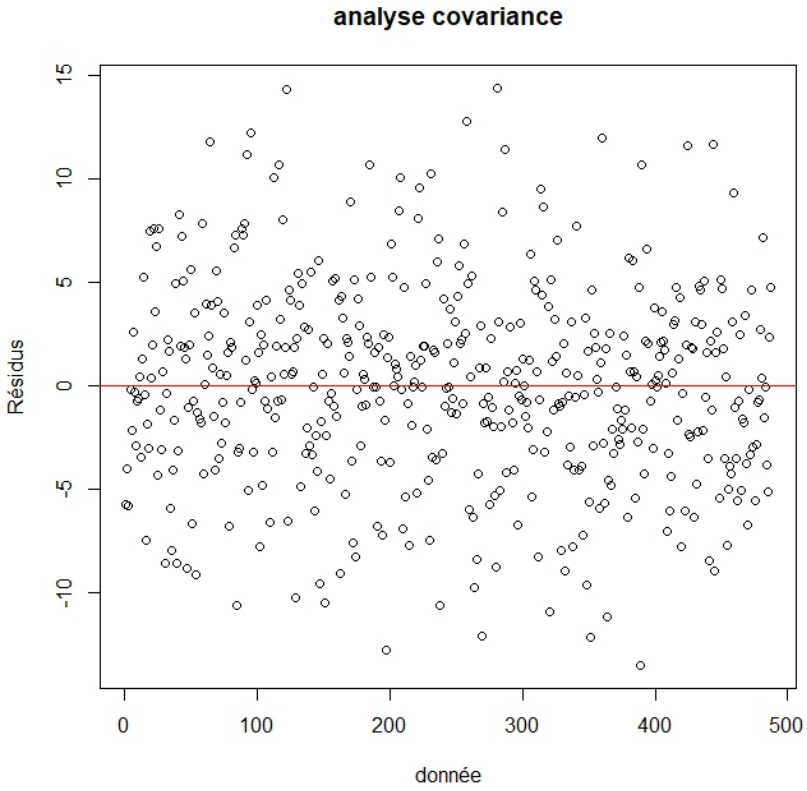


Figure 37: Vérification de l'hypothèse d'indépendance des erreurs

Le graphique affiche de nouveau un nuage de points homogène. La variance de l'erreur est stable tout au long de la descente : l'hypothèse de variance constante est validée.

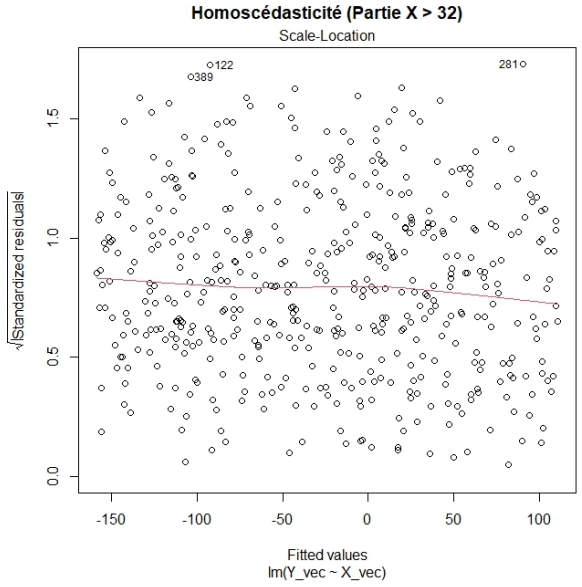


Figure 38: Validation de l'Homoscédasticité

4. Intervalles de Prédiction

Les hypothèses étant validées, la formule mathématique de l'intervalle est totalement adaptée. L'intervalle de prédiction à 95% accompagne la droite décroissante de manière parallèle, encadrant le nuage de points

de façon optimale.

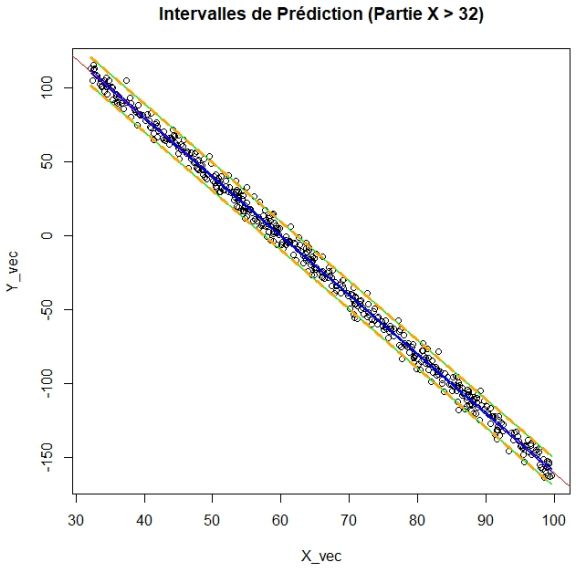


Figure 39: Intervalles de confiance et de prédiction (Phase Décroissante)

Conclusion globale

La stratégie consistant à scinder le jeu de données en deux au niveau de la rupture ($X = 32$) s'avère extrêmement fructueuse. Pour la phase décroissante comme pour la phase croissante, la modélisation par régression linéaire simple est statistiquement irréprochable. L'ensemble des hypothèses mathématiques fondamentales (Normalité et Homoscédasticité) est validé des deux côtés, ce qui garantit des prédictions totalement fiables sur l'ensemble du domaine étudié.

Analyse de Régression Linéaire Multiple : Jeu de données E

1.resumé statistique du modèle L1

Le résumé statistique de la fonction `lm()` évalue la pertinence globale de notre modèle de régression multiple complet (incluant les variables V1 à V5) :

- **Test de Fisher :** La p-valeur du test de Fisher est $< 2.2 \cdot 10^{-16}$. Étant strictement inférieure au seuil de risque $\alpha = 0,05$, on rejette l'hypothèse nulle stipulant que tous les coefficients sont nuls simultanément. Le modèle a du sens.
- Le **coefficient de détermination ajusté** R_a^2 est de $0,9998$. Le modèle explique ainsi 99,98% de la variance des données, ce qui indique un bon ajustement.
- **Significativité individuelle :** Malgré ce score parfait, les p-valeurs individuelles montrent que seules V1 et V5 sont significatives (p-valeurs $< 0,05$). Les variables V2, V3 et V4 ne le sont pas, justifiant la nécessité d'une sélection de variables par la suite.

```
> summary(L1)

Call:
lm(formula = Rep ~ ., data = Data)

Residuals:
    Min      1Q  Median      3Q     Max
-3.2282 -0.7001 -0.0117  0.6930  3.5818

Coefficients:
             Estimate Std. Error  t value Pr(>|t|)
(Intercept) -3.091445   0.473968   -6.522 1.71e-10 ***
V1           3.099713   0.002182 1420.344  < 2e-16 ***
V2           0.010738   0.009265    1.159   0.2470
V3           0.064268   0.037805    1.700   0.0898 .
V4           0.035810   0.021280    1.683   0.0930 .
V5          -5.865062   0.650876   -9.011  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.036 on 494 degrees of freedom
Multiple R-squared:  0.9998,    Adjusted R-squared:  0.9998
F-statistic: 4.041e+05 on 5 and 494 DF,  p-value: < 2.2e-16
```

Figure 40: Résumé statistique du modèle L1 et Test de Fisher

2. Hypothèse de Normalité du bruit (Parfaitement validée)

L'analyse de la **distribution normale** des **erreurs** est un prérequis pour valider les tests statistiques précédents. Ici, les résultats sont très solides :

- **Le test de Kolmogorov-Smirnov :** La p-valeur obtenue sur les résidus studentisés est de $0,9789$, supérieure au seuil de $0,05$, l'hypothèse nulle $\mathcal{H}_0$ est acceptée. L'hypothèse de normalité du bruit est validée mathématiquement.
- **Vérification visuelle (Q-Q plot) :** Le graphique Quantiles-Quantiles confirme le test. Les résidus standardisés s'alignent de manière presque parfaite sur la première bissectrice.

```
        Asymptotic one-sample Kolmogorov-Smirnov test

data:  residus_studentises
D = 0.021128, p-value = 0.9789
alternative hypothesis: two-sided
```

Figure 41: Résultat du test de Kolmogorov-Smirnov dans la console

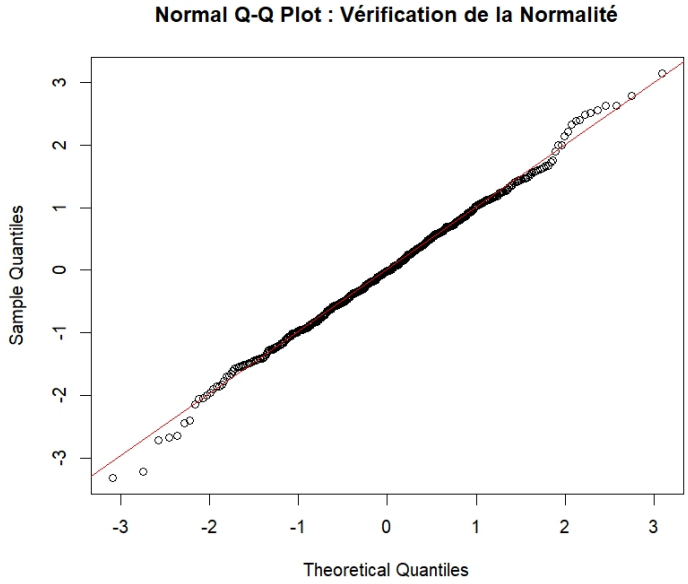


Figure 42: QQ-plot : Alignement parfait confirmant la normalité du bruit

3. Vérification des hypothèses fondamentales sur les résidus (Espérance, Indépendance et Variance)

- **Vérification de l'espérance :** La moyenne empirique des résidus calculée sous R est de $4.867 \cdot 10^{-17}$. Cette valeur étant égale au zéro numérique de la machine, l'hypothèse d'espérance nulle est vérifiée.

```
> mean(residuals(L1))
[1] 4.867135e-17
```

Figure 43: Vérification de l'espérance nulle des résidus

- **Vérification de l'indépendance des erreurs :** d'après le graphique, l'hypothèse d'indépendance ($cov(\epsilon_i, \epsilon_j) = 0$) est donc validée.

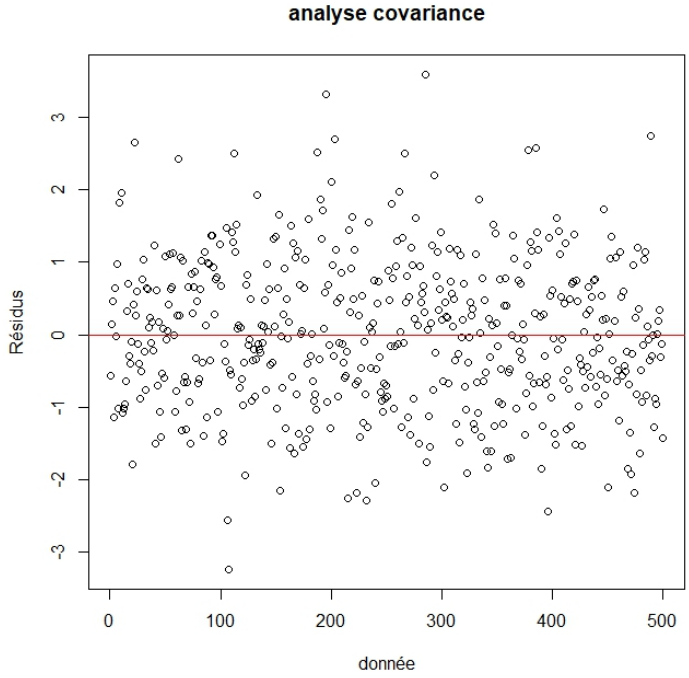


Figure 44: Vérification de l'hypothèse d'indépendance des erreurs (covariance nulle)

- **Vérification de l'homoscédasticité :**D'après notre on voit que la variance est contante, Donc l'hypothèse de l'homoscédasticité est vérifié.

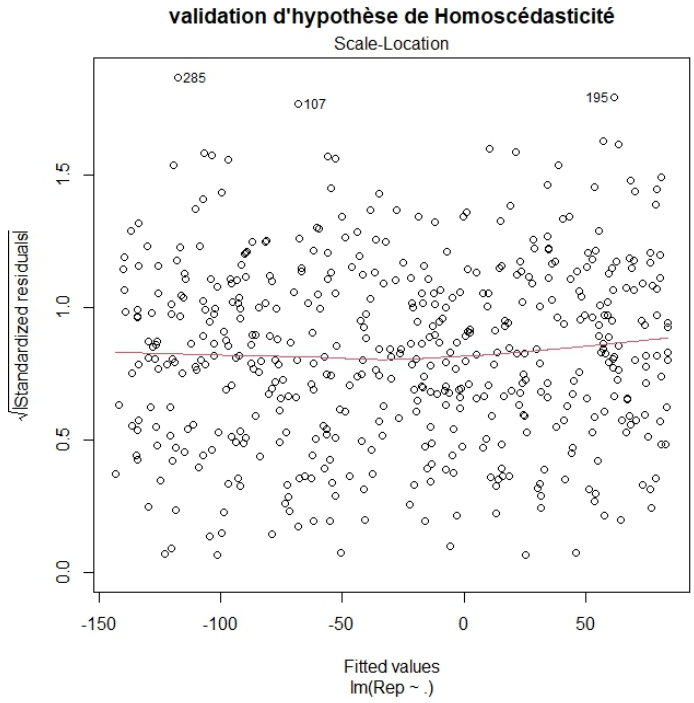


Figure 45: Validation de l'hypothèse d'homoscédasticité (variance constante)

L'objectif de cette section est de construire un modèle de prédiction pour la variable réponse **Rep** à partir de 5 variables explicatives potentielles (X1 à X5). Nous avons d'abord évalué le modèle complet

avant d'appliquer plusieurs méthodes de sélection pour conserver le modèle le plus simple et le plus robuste.

1. Évaluation du modèle complet

Nous avons généré un premier modèle de régression linéaire incluant l'ensemble des variables disponibles.

```
Call:
lm(formula = Rep ~ ., data = Data)

Coefficients:
(Intercept)           X1           X2           X3           X4           X5
   -3.09144      3.09971      0.01074      0.06427      0.03581     -5.86506

> summary(L1)

Call:
lm(formula = Rep ~ ., data = Data)

Residuals:
    Min      1Q  Median      3Q     Max
-3.2282 -0.7001 -0.0117  0.6930  3.5818

Coefficients:
             Estimate Std. Error  t value Pr(>|t|)
(Intercept) -3.091445   0.473968   -6.522 1.71e-10 ***
X1           3.099713   0.002182 1420.344  < 2e-16 ***
X2           0.010738   0.009265    1.159   0.2470
X3           0.064268   0.037805    1.700   0.0898 .
X4           0.035810   0.021280    1.683   0.0930 .
X5          -5.865062   0.650876   -9.011  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.036 on 494 degrees of freedom
Multiple R-squared:  0.9998,    Adjusted R-squared:  0.9998
F-statistic: 4.041e+05 on 5 and 494 DF,  p-value: < 2.2e-16
```

Figure 46: Résumé statistique du modèle complet

Interprétation :

- **Qualité globale :** Le modèle est globalement très significatif (p-valeur du test de Fisher $< 2.2e{-}16$) et explique quasiment 100% de la variance (R^2 ajusté $= 0.9998$).
- **Significativité individuelle (Test de Student) :** Seules les variables **X1** et **X5** ont une p-valeur très inférieure à 0.05. Les variables X2, X3 et X4 ne sont pas statistiquement significatives dans ce modèle complet et sont de fortes candidates à l'élimination.

2. Analyse des corrélations

Avant de sélectionner les variables, nous observons la matrice de corrélation pour repérer les liens directs.

```
> cor(Data)
             X1           X2          X3           X4          X5          Rep
X1   1.000000000 -0.003356206  0.03480352 -0.000316787  0.02240326  0.999855317
X2  -0.003356206  1.000000000 -0.01473839  0.014405594 -0.04663737 -0.002243632
X3   0.034803516 -0.014738394  1.00000000 -0.046935022  0.02934431  0.035745974
X4  -0.000316787  0.014405594 -0.04693502  1.000000000 -0.06683712  0.001251694
X5   0.022403261 -0.046637368  0.02934431 -0.066837124  1.00000000  0.015956971
Rep  0.999855317 -0.002243632  0.03574597  0.001251694  0.01595697  1.000000000
```

Figure 47: Matrice de corrélation des variables

Interprétation : La variable **X1** est très corrélée à la variable réponse (0.9998). À elle seule, elle semble contenir toute l'information nécessaire pour prédire la variable réponse. Les autres variables n'ont quasiment aucune corrélation linéaire avec la réponse.

3. Sélection de variables : Méthodes Exhaustive et Itérative

Pour éviter le surapprentissage et simplifier le modèle, nous avons appliqué les algorithmes de sélection classiques.

Méthode Exhaustive (Cp de Mallows)

Le critère du Cp de Mallows cherche le meilleur compromis en pénalisant les modèles trop complexes. La règle est de choisir un modèle dont le score Cp est petit et proche de $p + 1$.

```
$which
      1     2     3     4     5
1  TRUE FALSE FALSE FALSE FALSE
1 FALSE FALSE  TRUE FALSE FALSE
1 FALSE FALSE FALSE FALSE  TRUE
1 FALSE  TRUE FALSE FALSE FALSE
1 FALSE FALSE FALSE  TRUE FALSE
2  TRUE FALSE FALSE FALSE  TRUE
2  TRUE FALSE FALSE  TRUE FALSE
2  TRUE  TRUE FALSE FALSE FALSE
2  TRUE FALSE  TRUE FALSE FALSE
2 FALSE FALSE  TRUE FALSE  TRUE
2 FALSE FALSE  TRUE  TRUE FALSE
2 FALSE  TRUE  TRUE FALSE FALSE
2 FALSE FALSE FALSE  TRUE  TRUE
2 FALSE  TRUE FALSE FALSE  TRUE
2 FALSE  TRUE FALSE  TRUE FALSE
3  TRUE FALSE FALSE  TRUE  TRUE
3  TRUE FALSE  TRUE FALSE  TRUE
3  TRUE  TRUE FALSE FALSE  TRUE
3  TRUE  TRUE FALSE  TRUE FALSE
3  TRUE FALSE  TRUE  TRUE FALSE
3  TRUE  TRUE  TRUE FALSE FALSE
3 FALSE FALSE  TRUE  TRUE  TRUE
3 FALSE  TRUE  TRUE FALSE  TRUE
3 FALSE  TRUE  TRUE  TRUE FALSE
3 FALSE  TRUE FALSE  TRUE  TRUE
4  TRUE FALSE  TRUE  TRUE  TRUE
4  TRUE  TRUE  TRUE FALSE  TRUE
4  TRUE  TRUE FALSE  TRUE  TRUE
4  TRUE  TRUE  TRUE  TRUE FALSE
4 FALSE  TRUE  TRUE  TRUE  TRUE
5  TRUE  TRUE  TRUE  TRUE  TRUE

$label
[1] "(Intercept)" "1"           "2"           "3"           "4"           "5"

$size
 [1] 2 2 2 2 2 3 3 3 3 3 3 3 3 3 4 4 4 4 4 4 4 4 4 4 5 5 5 5 5 6

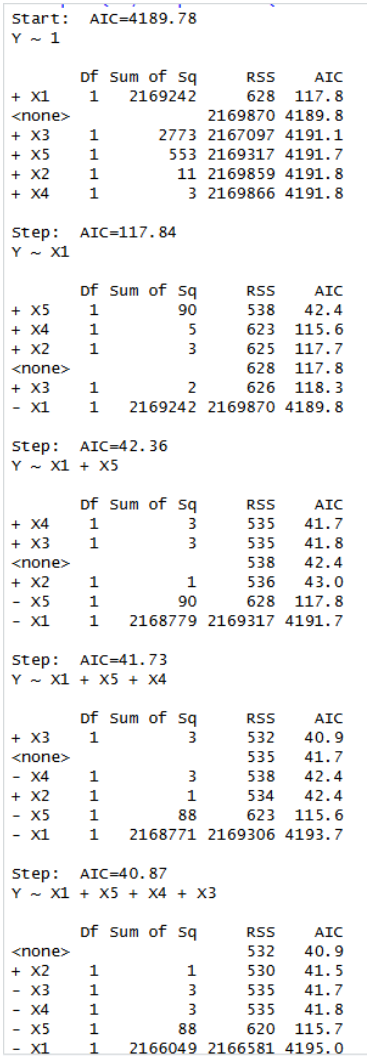
$Cp
 [1] 8.874755e+01 2.017859e+06 2.019927e+06 2.020431e+06 2.020438e+06 6.810474e+00 8.577606e+01 8.824814e+01
 [9] 8.893107e+01 2.017412e+06 2.017844e+06 2.017855e+06 2.019918e+06 2.019924e+06 2.020430e+06 6.183233e+00
[17] 6.217239e+00 7.475282e+00 8.537668e+01 8.566177e+01 8.836838e+01 2.017383e+06 2.017411e+06 2.017840e+06
[25] 2.019915e+06 5.343091e+00 6.831773e+00 6.889974e+00 8.519856e+01 2.017382e+06 6.000000e+00
```

Figure 48: Résultats de la sélection exhaustive

Interprétation : Le tableau indique que le modèle à 2 variables (X1 et X5, correspondant à la ligne avec un score Cp de 6.81) est le plus pertinent mathématiquement parmi les modèles simples.

Méthode Itérative (Stepwise - Critère AIC)

L'algorithme pas-à-pas (Stepwise) teste l'ajout et le retrait de variables pour minimiser le critère d'information AIC.



```
Start:  AIC=4189.78
Y ~ 1

       Df Sum of Sq     RSS    AIC
+ X1    1   2169242     628  117.8
<none>               2169870 4189.8
+ X3    1      2773 2167097 4191.1
+ X5    1       553 2169317 4191.7
+ X2    1        11 2169859 4191.8
+ X4    1         3 2169866 4191.8

Step:  AIC=117.84
Y ~ X1

       Df Sum of Sq     RSS    AIC
+ X5    1        90     538   42.4
+ X4    1         5     623  115.6
+ X2    1         3     625  117.7
<none>              628  117.8
+ X3    1         2     626  118.3
- X1    1   2169242 2169870 4189.8

Step:  AIC=42.36
Y ~ X1 + X5

       Df Sum of Sq     RSS    AIC
+ X4    1         3     535   41.7
+ X3    1         3     535   41.8
<none>              538   42.4
+ X2    1         1     536   43.0
- X5    1        90     628  117.8
- X1    1   2168779 2169317 4191.7

Step:  AIC=41.73
Y ~ X1 + X5 + X4

       Df Sum of Sq     RSS    AIC
+ X3    1         3     532   40.9
<none>              535   41.7
- X4    1         3     538   42.4
+ X2    1         1     534   42.4
- X5    1        88     623  115.6
- X1    1   2168771 2169306 4193.7

Step:  AIC=40.87
Y ~ X1 + X5 + X4 + X3

       Df Sum of Sq     RSS    AIC
<none>              532   40.9
+ X2    1         1     530   41.5
- X3    1         3     535   41.7
- X4    1         3     535   41.8
- X5    1        88     620  115.7
- X1    1   2166049 2166581 4195.0
```

Figure 49: Historique de l'algorithme Stepwise (AIC)

Interprétation : L'algorithme s'est arrêté sur un modèle conservant 4 variables (X1, X3, X4, X5) avec un AIC de 40.87. Cette méthode classique a tendance à conserver un peu trop de variables pour gratter d'infimes pourcentages de précision.

4. Sélection par Pénalisation : Méthode LASSO

Pour trancher, nous avons utilisé la méthode LASSO. Cet algorithme est beaucoup plus sévère : il écrase littéralement à zéro les coefficients des variables qui n'apportent pas d'information majeure.

```
Call:  cv.glmnet(x = as.matrix(X), y = Y, alpha = 1)

Measure: Mean-Squared Error

    Lambda Index Measure     SE Nonzero
min   1.75    40   4.369 0.2109       1
1se   1.75    40   4.369 0.2109       1
```

Figure 50: Recherche du Lambda optimal par validation croisée

```
6 x 1 sparse Matrix of class "dgCMatrix"
             lambda.1se
(Intercept)  -3.526863
X1            3.017068
X2            .
X3            .
X4            .
X5            .
```

Figure 51: Coefficients finaux du modèle LASSO

Interprétation : Le résultat est radical et sans appel. Le modèle LASSO optimal a mis à zéro (représenté par des points ".") les coefficients de X2, X3, X4 et X5. La méthode LASSO ne conserve **que la variable X1**.

Conclusion et Choix du Modèle Final

Bien que les méthodes classiques (Mallows et Stepwise) aient tenté de conserver X5 (voire d'autres variables) en raison d'une infime variance résiduelle mathématique, l'analyse montre que cela n'est pas nécessaire.

La corrélation initiale (0.999) et la sélection très stricte du LASSO convergent vers une conclusion claire : **la variable X1 suffit à elle seule pour prédire la variable réponse avec une précision exceptionnelle**. Le modèle de régression simple final retenu est donc : $Rep \sim X1$.

Analyse de Régression Linéaire Multiple : Jeu de données F

L'objectif est de construire un modèle prédictif pour la variable **Rep** à partir de 5 variables explicatives (X1 à X5). Nous allons comparer un modèle complet aux modèles réduits issus de différentes méthodes de sélection.

1. Évaluation du modèle complet

```
Call:
lm(formula = Rep ~ ., data = Data)

Coefficients:
(Intercept)           X1           X2           X3           X4           X5
     -2.252        3.099       -2.152        6.210       -5.301       -6.717

> summary(L1)

Call:
lm(formula = Rep ~ ., data = Data)

Residuals:
     Min       1Q   Median       3Q      Max
-2.82924 -0.67314 -0.00723  0.66928  2.62776

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -2.251503   0.082752  -27.21   <2e-16 ***
X1           3.099167   0.002199 1409.19   <2e-16 ***
X2          -2.151859   0.028192  -76.33   <2e-16 ***
X3           6.209929   0.001040 5970.84   <2e-16 ***
X4          -5.300889   0.019361 -273.79   <2e-16 ***
X5          -6.716664   0.401409  -16.73   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9955 on 494 degrees of freedom
Multiple R-squared:      1,     Adjusted R-squared:      1
F-statistic: 7.797e+06 on 5 and 494 DF,  p-value: < 2.2e-16
```

Figure 52: Résumé statistique du modèle complet

Interprétation :

- **Qualité globale :** Le modèle frôle la perfection mathématique (R^2 et R^2 ajusté $= 1$).
- **Significativité individuelle :** Contrairement au jeu de données précédent, **toutes** les variables (X1 à X5) ont une p-valeur extrêmement petite ($< 2e-16$). Le test de Student indique qu'elles sont toutes significatives dans ce modèle à 5 variables.

2. Analyse des corrélations

```
> cor(Data)
              X1          X2          X3          X4          X5         Rep
X1   1.00000000 -0.02476919  0.05646865 -0.01308955  0.05184309  0.28139317
X2  -0.02476919  1.00000000  0.03887517  0.03578310 -0.00311181  0.01792496
X3   0.05646865  0.03887517  1.00000000 -0.00378032  0.06627940  0.97284346
X4  -0.01308955  0.03578310 -0.00378032  1.00000000 -0.02322949 -0.05086249
X5   0.05184309 -0.00311181  0.06627940 -0.02322949  1.00000000  0.07377051
Rep  0.28139317  0.01792496  0.97284346 -0.05086249  0.07377051  1.00000000
```

Figure 53: Matrice de corrélation des variables

Interprétation : La matrice révèle un paradoxe. Seule la variable **X3** est fortement corrélée avec la réponse (0.97). Les autres ont des corrélations très faibles. Si elles sont significatives dans le modèle complet, c'est uniquement parce qu'elles viennent corriger de minuscules résidus de variance.

3. Sélection de variables : Méthodes Exhaustive et Itérative

Méthode Exhaustive (Cp de Mallows)

La règle du Cp de Mallows est de chercher le modèle ayant un score Cp le plus petit possible et proche de $p + 1$ (ici $5 + 1 = 6$).

```
$which
      1     2     3     4     5
1 FALSE FALSE  TRUE FALSE FALSE
1  TRUE FALSE FALSE FALSE FALSE
1 FALSE FALSE FALSE FALSE  TRUE
1 FALSE FALSE FALSE  TRUE FALSE
1 FALSE  TRUE FALSE FALSE FALSE
2  TRUE FALSE  TRUE FALSE FALSE
2 FALSE FALSE  TRUE  TRUE FALSE
2 FALSE  TRUE  TRUE FALSE FALSE
2 FALSE FALSE  TRUE FALSE  TRUE
2  TRUE FALSE FALSE FALSE  TRUE
2  TRUE FALSE FALSE  TRUE FALSE
2  TRUE  TRUE FALSE FALSE FALSE
2 FALSE FALSE FALSE  TRUE  TRUE
2 FALSE  TRUE FALSE FALSE  TRUE
2 FALSE  TRUE FALSE  TRUE FALSE
3  TRUE FALSE  TRUE  TRUE FALSE
3  TRUE  TRUE  TRUE FALSE FALSE
3  TRUE FALSE  TRUE FALSE  TRUE
3 FALSE  TRUE  TRUE  TRUE FALSE
3 FALSE FALSE  TRUE  TRUE  TRUE
3 FALSE  TRUE  TRUE FALSE  TRUE
3  TRUE FALSE FALSE  TRUE  TRUE
3  TRUE  TRUE FALSE FALSE  TRUE
3  TRUE  TRUE FALSE  TRUE FALSE
3 FALSE  TRUE FALSE  TRUE  TRUE
4  TRUE  TRUE  TRUE  TRUE FALSE
4  TRUE FALSE  TRUE  TRUE  TRUE
4  TRUE  TRUE  TRUE FALSE  TRUE
4 FALSE  TRUE  TRUE  TRUE  TRUE
4  TRUE  TRUE FALSE  TRUE  TRUE
5  TRUE  TRUE  TRUE  TRUE  TRUE

$label
[1] "(Intercept)" "1"           "2"           "3"           "4"           "5"

$size
 [1] 2 2 2 2 2 3 3 3 3 3 3 3 3 3 4 4 4 4 4 4 4 4 4 4 5 5 5 5 5 6

$Cp
 [1] 2.088142e+06 3.589747e+07 3.877221e+07 3.888352e+07 3.897185e+07 8.247850e+04 2.001347e+06 2.072691e+06
 [9] 2.084764e+06 3.576056e+07 3.581068e+07 3.587330e+07 3.867799e+07 3.875937e+07 3.886830e+07 6.098745e+03
[17] 7.507331e+04 8.237538e+04 1.988400e+06 1.998710e+06 2.069395e+06 3.567858e+07 3.573617e+07 3.578311e+07
[25] 3.866252e+07 2.839842e+02 5.829905e+03 7.496227e+04 1.985820e+06 3.565089e+07 6.000000e+00
```

Figure 54: Résultats de la sélection exhaustive

Interprétation : Les modèles simples ont des scores Cp immenses (plusieurs millions). La seule ligne acceptable est la dernière (les 5 variables "TRUE"), qui donne un Cp parfait de 6.00. La méthode exhaustive nous conseille de **tout garder**.

Méthode Itérative (Stepwise - Critère AIC)

```
Step:  AIC=1.47
Y ~ X3 + X1 + X4 + X2 + X5

       Df Sum of Sq      RSS    AIC
<none>                   490    1.5
- X5    1       277      767  224.0
- X2    1      5774     6263 1273.9
- X4    1     74287    74777 2513.8
- X1    1   1968040  1968530 4149.1
- X3    1  35331754 35332244 5592.8
```

Figure 55: Étape finale de l'algorithme Stepwise (AIC)

Interprétation : L'algorithme itératif arrive à la même conclusion. L'étape finale montre que retirer n'importe quelle variable (même X5 ou X2) ferait exploser le critère AIC (qui passerait de 1.5 à plus de 224). Le Stepwise conserve **les 5 variables**.

4. Sélection par Pénalisation : Méthode LASSO

Les méthodes classiques font du "surapprentissage" parfait. Voyons comment réagit la méthode LASSO, conçue pour forcer la simplicité.

```
Call:  cv.glmnet(x = as.matrix(X), y = Y, alpha = 1)

Measure: Mean-Squared Error

    Lambda Index Measure    SE Nonzero
min  4.511    45   91.58 27.55       3
1se  4.951    44  103.74 33.26       3
```

Figure 56: Recherche du Lambda optimal

```
6 x 1 sparse Matrix of class "dgCMatrix"
             lambda.1se
(Intercept) -10.669374
X1            2.874202
X2            .
X3            6.096975
X4           -3.229260
X5            .
```

Figure 57: Coefficients finaux du modèle LASSO

Interprétation : Le LASSO est beaucoup plus pragmatique. Il identifie que 3 variables suffisent pour capter l'essentiel de l'information. Il conserve **X1, X3 et X4**, et annule strictement les variables X2 et X5 (représentées par des ".").

Conclusion et Choix du Modèle Final

Ce jeu de données illustre parfaitement les limites des méthodes classiques (Stepwise, Mallows) qui se laissent piéger par la recherche de la perfection mathématique ($R^2 = 1$) et conservent toutes les variables.

Grâce à l'analyse de corrélation et à la pénalisation LASSO, nous adoptons un modèle plus robuste et moins sujet au surapprentissage. Le modèle final retenu ne conservera que 3 variables : **Rep** $\sim$ **X1** $+$ **X3** $+$ **X4**.

Analyse de Régression Linéaire Multiple : Jeu de données G

1. resumé statistique du modèle L1 (modèle de base avec tous les variables)

Le résumé statistique de la fonction `lm()` évalue la pertinence globale de notre modèle de régression multiple complet (incluant les variables V1 à V7) :

- **Test de Fisher :** La p-valeur du test de Fisher (F-statistic) est $< 2.2 \cdot 10^{-16}$. Étant strictement inférieure au seuil de risque $\alpha = 0,05$, on rejette fermement l'hypothèse nulle stipulant que tous les coefficients sont nuls simultanément. Le modèle a donc globalement un sens.
- **Pouvoir explicatif :** Le **coefficient de détermination ajusté** R^2_a est de $0,9962$. Le modèle explique ainsi 99,62% de la variance des données, ce qui indique un ajustement exceptionnel.
- **Significativité individuelle (Limites) :** Malgré ce score très élevé, les p-valeurs individuelles montrent que seule la variable V5 est significative (p-valeur $< 0,05$). Les variables V1, V2, V3, V4, V6 et V7 ne le sont pas, justifiant la nécessité d'une sélection de variables par la suite.

```
> summary(L1)

Call:
lm(formula = Rep ~ ., data = Data)

Residuals:
   Min     1Q Median     3Q    Max
-7.421 -1.354 -0.003  1.363  7.911

Coefficients:
            Estimate Std. Error  t value Pr(>|t|)
(Intercept)  0.71228    0.13438    5.300 1.21e-07 ***
V1           0.76698    0.64629    1.187    0.235
V2           0.72569    0.64625    1.123    0.262
V3          -0.02064    0.01484   -1.391    0.164
V4          -0.17458    0.18612   -0.938    0.348
V5           3.10338    0.00272 1140.873  < 2e-16 ***
V6          -0.01979    0.05770   -0.343    0.732
V7          -0.02269    0.01403   -1.617    0.106
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.038 on 4992 degrees of freedom
Multiple R-squared:  0.9962,    Adjusted R-squared:  0.9962
F-statistic: 1.864e+05 on 7 and 4992 DF,  p-value: < 2.2e-16
```

Figure 58: Résumé statistique du modèle L1 et Test de Fisher

2. Hypothèse de Normalité du bruit (Parfaitement validée)

L'analyse de la **distribution normale** des **erreurs** (bruit) est un prérequis pour valider les tests statistiques précédents. Ici, les résultats sont très solides :

- **Le test de Kolmogorov-Smirnov :** La p-valeur obtenue sur les résidus studentisés est de $0,9791$. Étant très largement supérieure au seuil de $0,05$, l'hypothèse nulle $\mathcal{H}_0$ est fermement acceptée. L'hypothèse de normalité du bruit est validée mathématiquement.
- **Vérification visuelle (Q-Q plot) :** Le graphique Quantiles-Quantiles confirme parfaitement le test statistique. Les résidus standardisés s'alignent de manière presque parfaite sur la première bissectrice, sans aucune déviation notable aux extrémités.

```
        Asymptotic one-sample Kolmogorov-Smirnov test

data:  residus_studentises
D = 0.0066755, p-value = 0.9791
alternative hypothesis: two-sided
```

Figure 59: Résultat du test de Kolmogorov-Smirnov dans la console

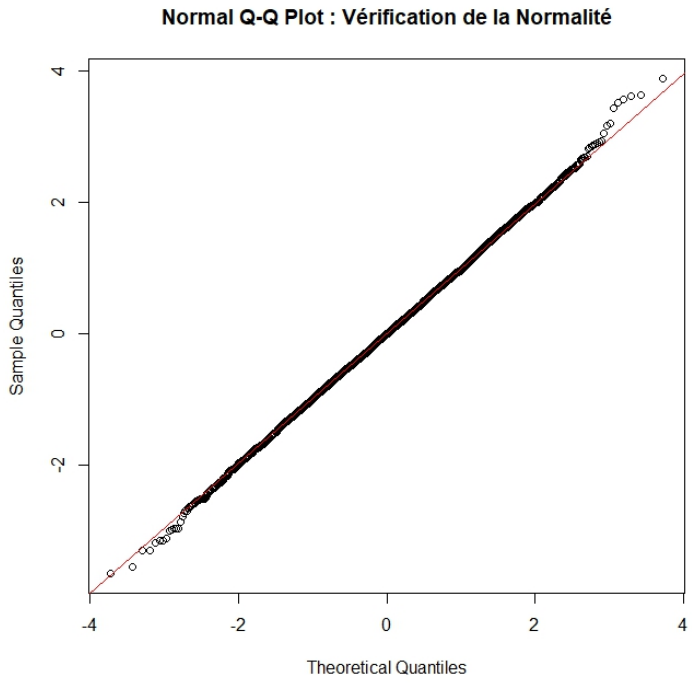


Figure 60: QQ-plot : Alignement parfait confirmant la normalité du bruit

3. Vérification des hypothèses fondamentales sur les résidus (Espérance, Indépendance et Variance)

- **Vérification de l'espérance :** La moyenne empirique des résidus calculée sous R est de $7.927 \cdot 10^{-18}$. Cette valeur étant égale au zéro numérique de la machine, l'hypothèse d'espérance nulle ($E[\epsilon_i] = 0$) est parfaitement vérifiée.

```
> mean(residuals(L1))
[1] 7.92786e-18
```

Figure 61: Vérification de l'espérance nulle des résidus

- **Vérification de l'indépendance des erreurs :** D'après le graphique, l'hypothèse d'indépendance ($cov(\epsilon_i, \epsilon_j) = 0$) est donc validée.

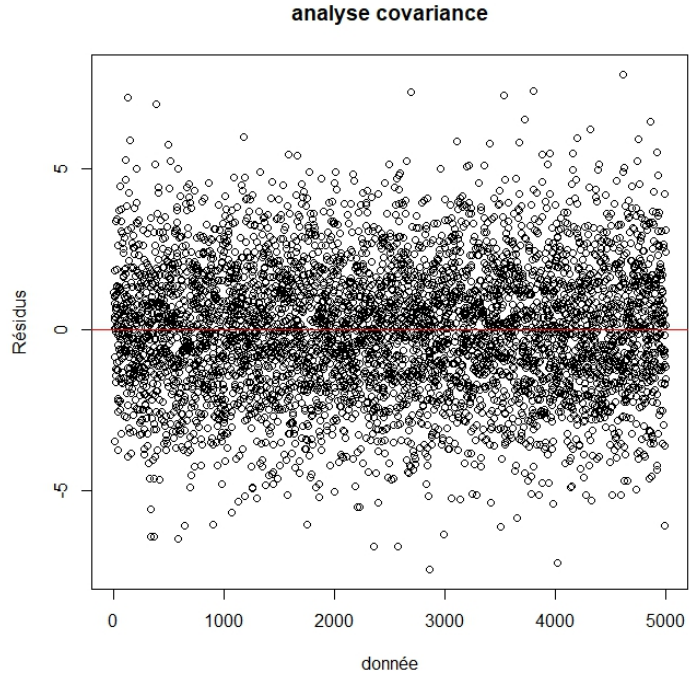


Figure 62: Vérification de l'hypothèse d'indépendance des erreurs (covariance nulle)

- **Vérification de l'homoscédasticité :** D'après notre graphique on voit que la variance est constante, Donc l'hypothèse de l'homoscédasticité est vérifiée.

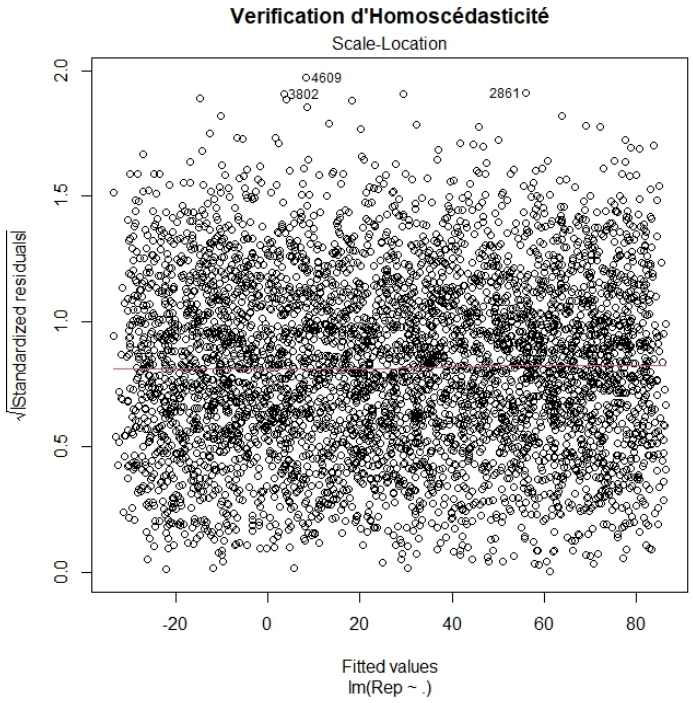


Figure 63: Validation de l'hypothèse d'homoscédasticité (variance constante)

L'objectif est d'expliquer la variable **Rep** à l'aide de 7 variables explicatives (X1 à X7). Ce jeu de données présente de nouveaux défis qui vont mettre à l'épreuve nos algorithmes de sélection.

1. Évaluation du modèle complet

```
Coefficients:
(Intercept)          X1          X2          X3          X4          X5          X6          X7
    0.71228     0.76698     0.72569    -0.02064    -0.17458     3.10338    -0.01979    -0.02269

> summary(L1)

Call:
lm(formula = Rep ~ ., data = Data)

Residuals:
   Min     1Q Median     3Q    Max
-7.421 -1.354 -0.003  1.363  7.911

Coefficients:
            Estimate Std. Error  t value Pr(>|t|)
(Intercept)  0.71228    0.13438    5.300 1.21e-07 ***
X1           0.76698    0.64629    1.187    0.235
X2           0.72569    0.64625    1.123    0.262
X3          -0.02064    0.01484   -1.391    0.164
X4          -0.17458    0.18612   -0.938    0.348
X5           3.10338    0.00272 1140.873  < 2e-16 ***
X6          -0.01979    0.05770   -0.343    0.732
X7          -0.02269    0.01403   -1.617    0.106
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.038 on 4992 degrees of freedom
Multiple R-squared:  0.9962,    Adjusted R-squared:  0.9962
F-statistic: 1.864e+05 on 7 and 4992 DF,  p-value: < 2.2e-16
```

Figure 64: Résumé statistique du modèle complet (7 variables)

Interprétation :

- **Qualité globale :** Le modèle explique remarquablement bien les données (R^2 ajusté $= 0.9962$).
- **Significativité individuelle :** Paradoxalement, bien que le modèle soit excellent, **seule la variable X5 est significative** (p-valeur $< 2e-16$). Toutes les autres variables (X1, X2, X3, X4, X6, X7) ont des p-valeurs supérieures à 0.05.

2. Analyse des corrélations

La matrice de corrélation permet de comprendre pourquoi le test de Student rejette la majorité des variables.

```
              X1           X2           X3           X4           X5           X6           X7
X1   1.000000000  0.999015177  0.0084995459  0.002765928 -0.005095601 -0.0143495100 -0.0084316634
X2   0.999015177  1.000000000  0.0082098079  0.003529631 -0.004579547 -0.0134033289 -0.0079665017
X3   0.008499546  0.008209808  1.0000000000  0.002872892  0.015873489 -0.0144985989  0.0003864543
X4   0.002765928  0.003529631  0.0028728917  1.000000000 -0.010209979  0.0174679626  0.0029494188
X5  -0.005095601 -0.004579547  0.0158734892 -0.010209979  1.000000000 -0.0017865545 -0.0060805920
X6  -0.014349510 -0.013403329 -0.0144985989  0.017467963 -0.001786554  1.0000000000 -0.0006661321
X7  -0.008431663 -0.007966502  0.0003864543  0.002949419 -0.006080592 -0.0006661321  1.0000000000
Rep  0.040413861  0.040926054  0.0149961149 -0.010872268  0.997052040 -0.0027095129 -0.0078534113
              Rep
X1   0.040413861
X2   0.040926054
X3   0.014996115
X4  -0.010872268
X5   0.997052040
X6  -0.002709513
X7  -0.007853411
Rep  1.000000000
```

Figure 65: Matrice de corrélation des variables

Interprétation :

1. La variable **X5** est, comme attendu, extrêmement corrélée à la réponse (0.997).
2. Il y a une forte colinéarité entre X1 et X2 (corrélation de 0.999). Elles apportent exactement la même information. C'est ce qui pose problème avec le modèle complet : l'ordinateur ne sait pas laquelle choisir, donc il rend les deux statistiquement non-significatives.

3. Sélection de variables : Méthodes Exhaustive et Itérative

Méthode Exhaustive (Cp de Mallows)

```
$cp
 [1] 2.713065e+03 1.302266e+06 1.302321e+06 1.304165e+06 1.304305e+06 1.304379e+06 1.304450e+06 4.756543e+00
 [9] 5.048783e+00 2.710866e+03 2.713937e+03 2.714161e+03 2.714437e+03 1.301987e+06 1.302042e+06 1.302109e+06
[17] 1.302120e+06 4.168673e+00 4.381818e+00 4.803871e+00 5.139303e+00 5.563642e+00 5.884839e+00 6.100733e+00
[25] 6.657516e+00 6.916263e+00 2.711734e+03 4.218498e+00 4.474815e+00 4.938926e+00 5.305683e+00 5.443008e+00
[33] 5.630758e+00 5.940002e+00 6.068835e+00 6.199317e+00 6.248363e+00 5.008849e+00 5.363294e+00 5.544022e+00
[41] 6.039518e+00 6.105571e+00 6.326445e+00 6.731200e+00 6.823748e+00 7.215823e+00 7.321618e+00 6.117647e+00
[49] 6.879848e+00 7.260974e+00 7.408365e+00 7.935075e+00 8.614721e+00 1.301597e+06 8.000000e+00
```

Figure 66: Scores Cp des différents sous-modèles

Interprétation : De nombreux modèles ont un score Cp gigantesque , ce qui prouve qu'ils sont très mauvais. Les modèles viables sont ceux qui intègrent impérativement la variable X5 combinée à une ou deux autres.

Méthode Itérative (Stepwise - Critère AIC)

L'algorithme Stepwise est ici configuré pour construire le modèle petit à petit .

```
Start:  AIC=34962.62
Y ~ 1

       Df Sum of Sq     RSS   AIC
+ X5    1   5408125   32027  9290
+ X2    1      9112 5431041 34956
+ X1    1      8885 5431267 34956
<none>              5440153 34963
+ X3    1      1223 5438929 34963
+ X4    1       643 5439510 34964
+ X7    1       336 5439817 34964
+ X6    1        40 5440113 34965

Step:  AIC=9289.77
Y ~ X5

       Df Sum of Sq     RSS   AIC
+ X1    1     11260   20767  7126
+ X2    1     11259   20769  7126
+ X7    1        17   32010  9289
<none>               32027  9290
+ X6    1         5   32023  9291
+ X3    1         4   32024  9291
+ X4    1         3   32025  9291
- X5    1   5408125 5440153 34963

Step:  AIC=7125.73
Y ~ X5 + X1

       Df Sum of Sq     RSS   AIC
+ X7    1        11   20757  7125
<none>               20767  7126
+ X3    1         8   20759  7126
+ X2    1         5   20762  7127
+ X4    1         4   20764  7127
+ X6    1         0   20767  7128
- X1    1     11260   32027  9290
- X5    1   5410500 5431267 34956

Step:  AIC=7125.15
Y ~ X5 + X1 + X7

       Df Sum of Sq     RSS   AIC
<none>               20757  7125
+ X3    1         8   20749  7125
- X7    1        11   20767  7126
+ X2    1         5   20752  7126
+ X4    1         4   20753  7126
+ X6    1         0   20756  7127
- X1    1     11253   32010  9289
- X5    1   5410204 5430960 34958
```

Figure 67: Historique de l'algorithme Stepwise (AIC)

Interprétation : L'algorithme part de rien et intègre immédiatement **X5**, ce qui fait chuter spectaculairement l'AIC (de 34962 à 9289). Ensuite, il ajoute **X1** et **X7** pour gratter d'infimes optimisations. Il s'arrête sur le modèle à 3 variables : **X5** + **X1** + **X7**.

4. Sélection par Pénalisation : Méthode LASSO

```
Call:  cv.glmnet(x = as.matrix(X), y = Y, alpha = 1)

Measure: Mean-Squared Error

    Lambda Index Measure      SE Nonzero
min 0.1491    59   4.204 0.07334       3
1se 0.2375    54   4.272 0.07074       3
```

Figure 68: Recherche du Lambda optimal

```
8 x 1 sparse Matrix of class "dgCMatrix"
            lambda.1se
(Intercept) 0.64280592
X1          1.19456607
X2          0.06142988
X3          .
X4          .
X5          3.08088527
X6          .
X7          .
```

Figure 69: Coefficients finaux du modèle LASSO

Interprétation : Le LASSO, avec son lambda optimal, décide lui aussi de ne conserver que 3 variables. Cependant, à cause de la forte corrélation entre X1 et X2 vue précédemment, le LASSO est légèrement perturbé : il conserve **X1, X2 et X5**.

Conclusion et Choix du Modèle Final

Ce jeu de données est un cas d'école de multicolinéarité.

Les algorithmes automatiques (Stepwise et LASSO) sont tous d'accord sur un point absolu : la variable X5 est le moteur du modèle. En revanche, ils se contredisent sur les variables secondaires à conserver (Stepwise veut X7, LASSO veut X2) car ces variables n'apportent en réalité que du "bruit" mathématique. De plus, X1 et X2 sont des clones.

En tant que statisticien pragmatique, la conclusion est claire : la matrice de corrélation (0.997) et la toute première étape du Stepwise prouvent que la variable X5 se suffit à elle-même. Le modèle final le plus robuste, le plus simple et le moins sensible au surapprentissage est une simple régression linéaire : **Rep $\sim$ X5**. L'ajout de X1 pourrait éventuellement se justifier pour un infime gain de précision, mais au risque de complexifier inutilement le modèle.

5 Analyse de la variance à un facteur: Jeu de données H

Dans cette partie, nous étudions l'influence d'une variable explicative qualitative (le facteur, ici l'espèce) sur une variable réponse quantitative (la longueur des pétales). L'objectif est de déterminer si l'appartenance à un groupe modifie significativement la valeur de la réponse.

5.1 Exploration Visuelle

Avant d'ajuster le modèle, nous avons réalisé une exploration graphique de nos données afin d'observer la distribution de la longueur des pétales pour chaque modalité de notre facteur.

L'observation des boîtes à moustaches montre que les distributions varient fortement selon les groupes (0 à 5). Les médianes et les moyennes (indiquées par des croix rouges) ne sont pas alignées, ce qui suggère fortement que le facteur étudié a une influence sur la variable réponse.

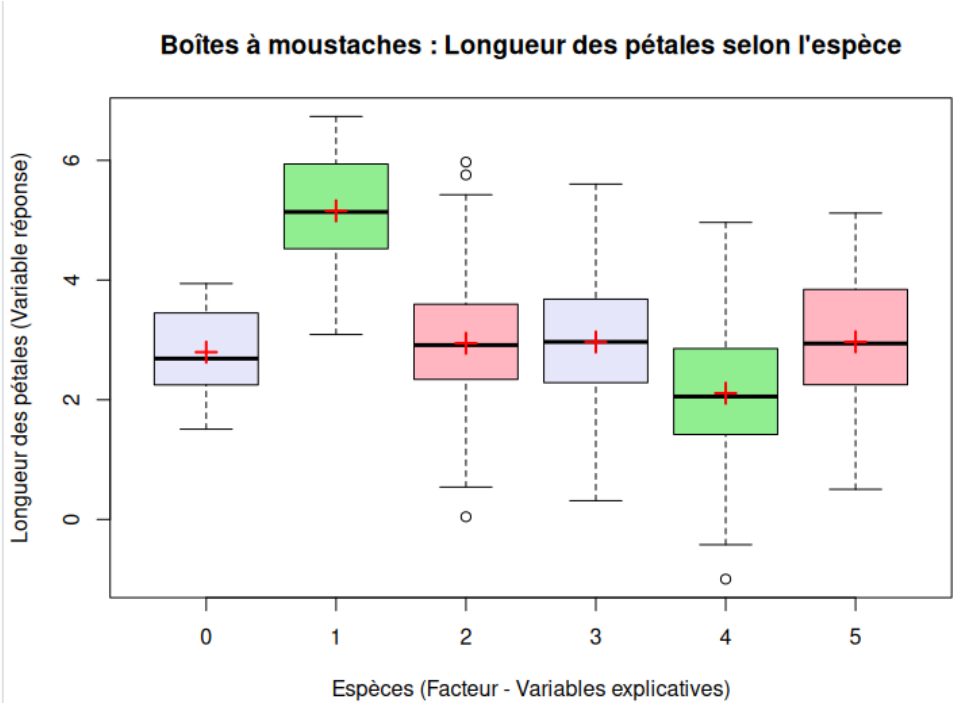


Figure 70: Boîtes à moustaches de la variable réponse selon les modalités du facteur. Les croix rouges indiquent les moyennes.

5.2 Test d'influence globale

Pour confirmer notre intuition visuelle, nous avons procédé à une analyse de la variance. Le test confronte l'hypothèse nulle $\mathcal{H}_0 : \mu_1 = \mu_2 = \ldots = \mu_l$ (absence d'effet du facteur) à l'hypothèse alternative $\mathcal{H}_1$ (au moins une moyenne diffère).

```
             Df Sum Sq Mean Sq F value Pr(>F)
X             5  514.3  102.86   106.8 <2e-16 ***
Residuals   994  957.5    0.96
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
>
```

Figure 71: Résultats du test d'influence globale du facteur.

D'après les résultats obtenus, la statistique de Fisher prend la valeur $F = 106.8$. La p-value associée est extrêmement faible ($< 2.2 \times 10^{-16}$), largement inférieure au seuil de signification classique de 5%. Nous rejetons donc $\mathcal{H}_0$: le facteur a une influence hautement significative sur la variable réponse.

5.3 Estimation des effets spécifiques

Pour contourner le problème de la matrice non inversible inhérente à l'ANOVA, R choisit par défaut de fixer l'effet de la première modalité à zéro (hypothèse $\mu_0 = 0$). Les autres coefficients s'interprètent alors comme des écarts par rapport à ce niveau de référence.

L'ordonnée à l'origine (*Intercept* estimé à 2.7950) correspond à la moyenne de la modalité de référence. On remarque que les modalités X1 et X4 ont des coefficients significatifs (p-values respectives de 3.31×10^{-14} et 0.0183), ce qui indique que ces groupes diffèrent de manière significative du groupe de référence.

5.4 Vérification des hypothèses du modèle

Enfin, le modèle d'analyse de la variance suppose que le bruit aléatoire (ϵ_i) suit une loi normale, est centré, et possède une variance constante (homoscédasticité). Nous vérifions ces hypothèses graphiquement.

```
Residuals:
     Min       1Q   Median       3Q      Max
-3.10563 -0.65373 -0.02314  0.71259  3.02594

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   2.7950     0.2833   9.865  < 2e-16 ***
X1            2.3608     0.3067   7.699 3.31e-14 ***
X2            0.1495     0.2902   0.515   0.6066
X3            0.1700     0.2883   0.590   0.5555
X4           -0.6857     0.2901  -2.364   0.0183 *
X5            0.1723     0.3025   0.570   0.5689
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.9815 on 994 degrees of freedom
Multiple R-squared:  0.3494,    Adjusted R-squared:  0.3462
F-statistic: 106.8 on 5 and 994 DF,  p-value: < 2.2e-16
```

Figure 72: Estimation des paramètres du modèle linéaire.

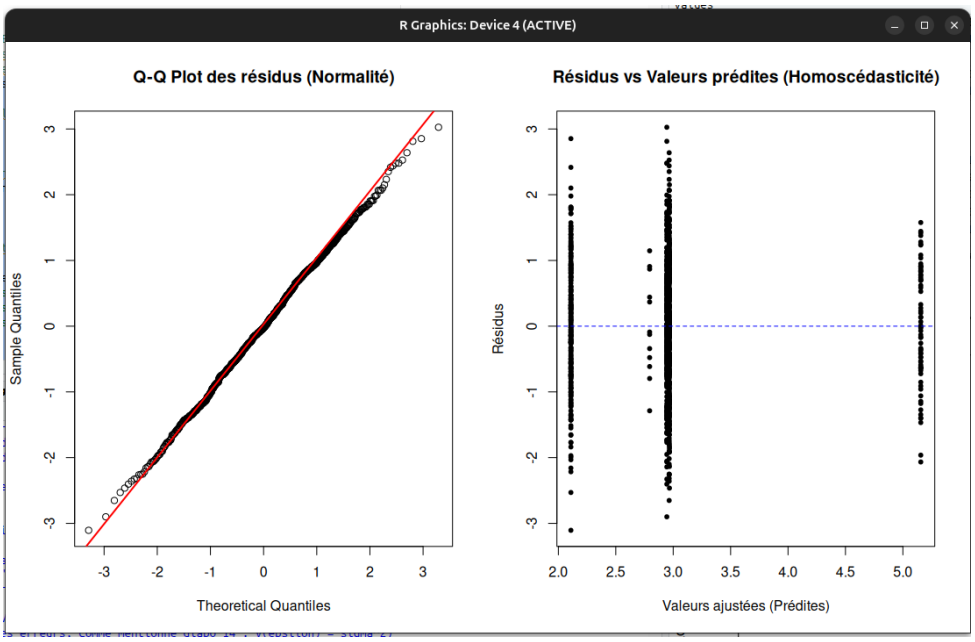


Figure 73: Analyse des résidus : Q-Q plot et Résidus vs Valeurs prédites.

- **Normalité :** Sur le *Q-Q Plot*, les points s'alignent globalement bien le long de la droite théorique rouge. L'hypothèse de normalité des résidus est donc jugée acceptable.
- **Homoscédasticité :** Sur le graphique des résidus en fonction des valeurs prédites, l'amplitude de dispersion des points autour de la droite horizontale d'ordonnée 0 semble relativement constante d'un groupe de valeurs ajustées à l'autre. L'hypothèse d'homoscédasticité ($V[\epsilon_i] = \sigma^2$) n'est pas violée.

5.5 Analyse de la variance à un facteur: Jeu de données I

Dans cette partie, nous étudions l'influence d'une variable explicative qualitative (le facteur, ici constitué de 4 groupes) sur une variable réponse quantitative. L'objectif est de déterminer si l'appartenance à un groupe modifie significativement la valeur de la réponse.

5.6 Exploration Visuelle

Avant d'ajuster le modèle, nous avons réalisé une exploration graphique de nos données afin d'observer la distribution de la variable réponse pour chaque modalité de notre facteur.

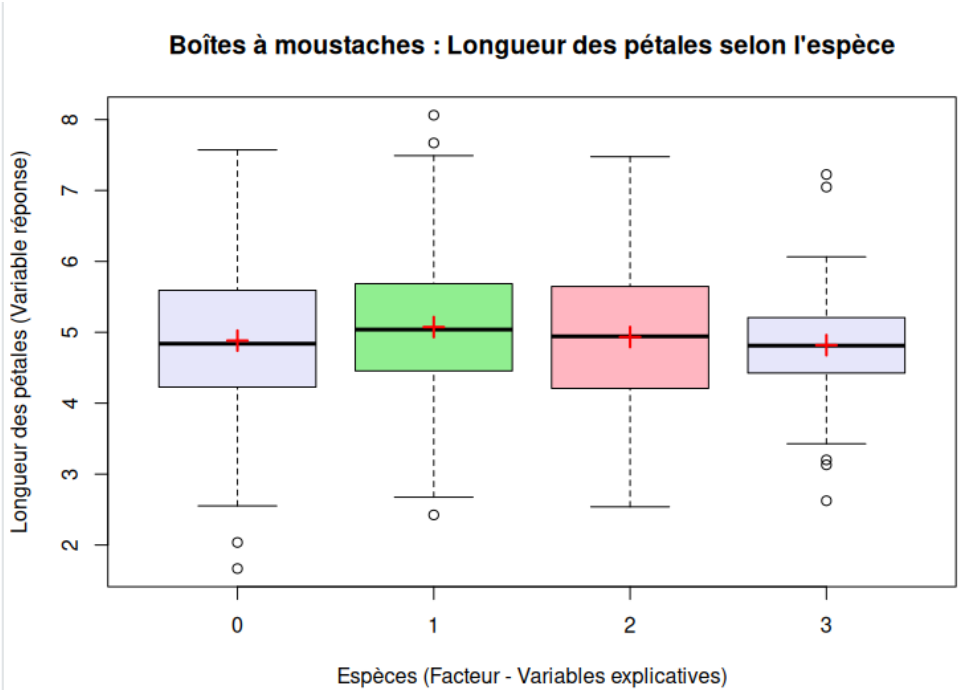


Figure 74: Boîtes à moustaches de la variable réponse selon les modalités du facteur. Les croix rouges indiquent les moyennes.

Contrairement à ce que l'on pourrait observer dans d'autres jeux de données, l'observation des boîtes à moustaches montre ici que les distributions sont très similaires pour les 4 groupes (0 à 3). Les médianes et les moyennes (indiquées par des croix rouges) sont pratiquement alignées horizontalement autour de la valeur 5. Cela suggère visuellement que le facteur étudié a peu ou pas d'influence sur la variable réponse.

5.7 Test d'influence globale

Pour confirmer notre intuition visuelle, nous avons procédé à une analyse de la variance. Le test confronte l'hypothèse nulle $\mathcal{H}_0 : \mu_0 = \mu_1 = \mu_2 = \mu_3$ (absence d'effet du facteur) à l'hypothèse alternative $\mathcal{H}_1$ (au moins une moyenne diffère).

D'après les résultats obtenus, la statistique de Fisher prend la valeur $F = 2.11$. La p-value associée est de 0.0977. Cette valeur étant supérieure au seuil de signification classique de 5% (0.05), nous ne pouvons pas rejeter l'hypothèse nulle $\mathcal{H}_0$. Nous concluons donc que le facteur n'a pas une influence globalement significative sur la variable réponse au seuil de 5%.

```
> summary(modele_anova)
             Df Sum Sq Mean Sq F value Pr(>F)
X             3    6.0  1.9959    2.11 0.0977 .
Residuals   696  658.5  0.9461
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
>
```

Figure 75: Résultats du test d'influence globale du facteur.

5.8 Estimation des effets spécifiques

Pour contourner le problème de la matrice non inversible inhérente à l'ANOVA, R choisit par défaut de fixer l'effet de la première modalité à zéro (hypothèse $\mu_0 = 0$). Les autres coefficients s'interprètent alors comme des écarts par rapport à ce niveau de référence (le groupe 0).

```
> summary.lm(modele_anova)

Call:
aov(formula = Y ~ X, data = data)

Residuals:
    Min      1Q  Median      3Q     Max
-3.2146 -0.6410 -0.0208  0.6676  2.9881

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.88228    0.07813  62.493   <2e-16 ***
X1           0.19156    0.09495   2.018    0.044 *
X2           0.05098    0.10787   0.473    0.637
X3          -0.06345    0.15941  -0.398    0.691
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.9727 on 696 degrees of freedom
Multiple R-squared:  0.009012,  Adjusted R-squared:  0.00474
F-statistic:  2.11 on 3 and 696 DF,  p-value: 0.09768
```

Figure 76: Estimation des paramètres du modèle linéaire.

L'ordonnée à l'origine (*Intercept* estimé à 4.88228) correspond à la moyenne de la modalité de référence (groupe 0). En observant les autres modalités, on remarque que les p-values pour X2 (0.637) et X3 (0.691) sont très élevées, confirmant qu'elles ne diffèrent pas significativement du groupe de référence. Seule la modalité X1 montre une très légère différence à la limite de la significativité ($p = 0.044$), mais cela ne suffit pas à rendre le modèle global pertinent.

5.9 Vérification des hypothèses du modèle

Enfin, le modèle d'analyse de la variance suppose que le bruit aléatoire (ϵ_i) suit une loi normale, est centré, et possède une variance constante (homoscédasticité). Nous vérifions ces hypothèses graphiquement.

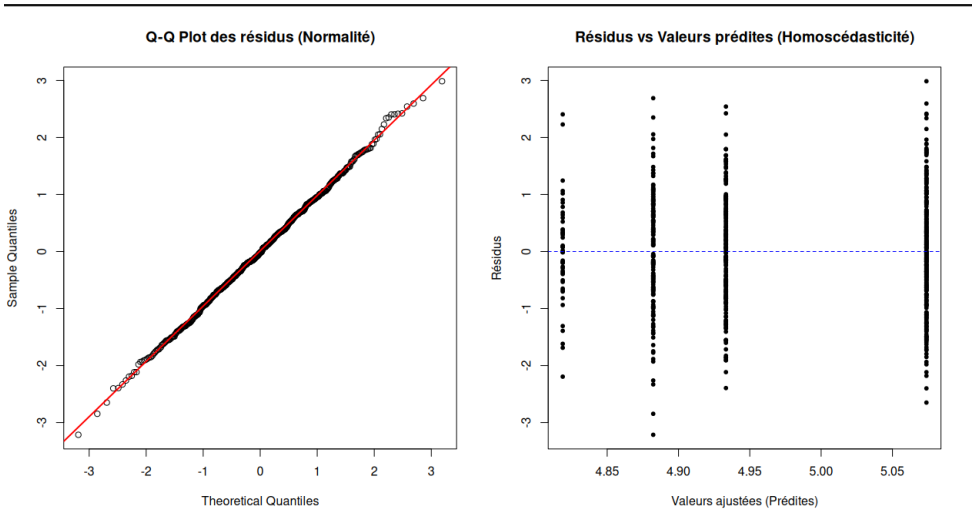


Figure 77: Analyse des résidus : Q-Q plot et Résidus vs Valeurs prédites.

- **Normalité :** Sur le *Q-Q Plot*, les points s'alignent de manière quasi-parfaite le long de la droite théorique rouge. L'hypothèse de normalité des résidus est donc tout à fait validée.
- **Homoscédasticité :** Sur le graphique des résidus en fonction des valeurs prédites, l'amplitude de dispersion des points autour de la droite horizontale d'ordonnée 0 est constante d'un groupe à l'autre. L'hypothèse d'homoscédasticité ($V[\epsilon_i] = \sigma^2$) est parfaitement respectée.

En conclusion, bien que les hypothèses mathématiques du modèle soient parfaitement vérifiées, l'analyse montre que le facteur étudié n'explique pas de manière significative les variations de notre variable réponse.

6 Généralisation : Régression Polynomiale

Dans cette section, nous abordons une généralisation du modèle de régression linéaire. Bien que la relation entre notre variable explicative (X) et notre variable réponse (Y) ne soit pas strictement linéaire, nous pouvons tout de même utiliser le cadre de la régression linéaire multiple en introduisant des termes polynomiaux (ici X^2 et X^3) comme nouvelles variables explicatives.

6.1 Exploration Visuelle

La première étape consiste à observer la forme de la relation entre X et Y à travers un nuage de points.

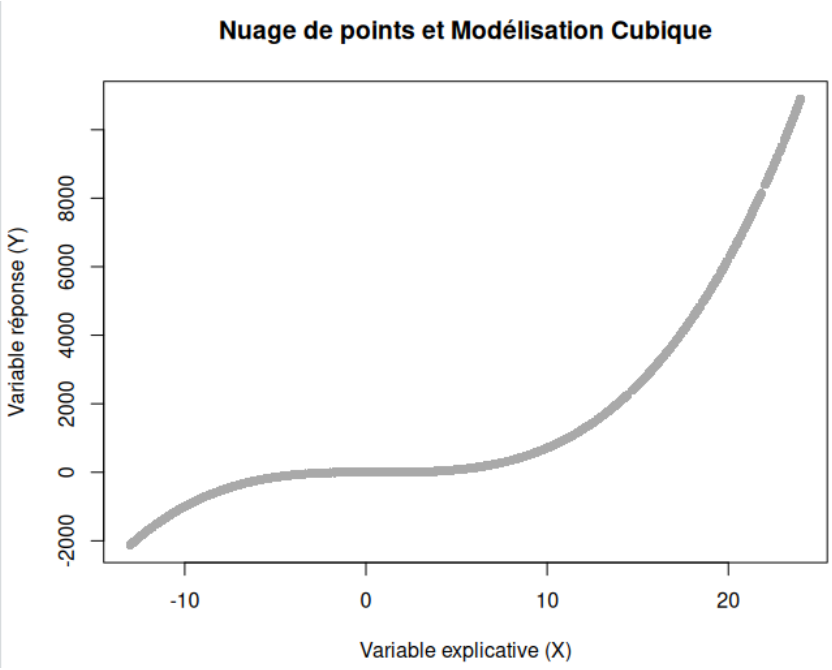


Figure 78: Nuage de points illustrant la relation entre la variable explicative et la variable réponse.

L'observation de la Figure 78 révèle une courbure très marquée, avec deux changements de concavité caractéristiques d'une fonction de degré 3. Une régression linéaire simple (une droite) serait ici totalement inadaptée. Cela justifie pleinement le choix d'un modèle polynomial cubique de la forme :

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \beta_3 X_i^3 + \epsilon_i$$

6.2 Ajustement du modèle et Résultats

Nous avons ajusté ce modèle cubique à l'aide de la fonction I() disponible sur R. Les résultats des estimations des paramètres sont présentés ci-dessous.

```
Coefficients:
             Estimate Std. Error  t value Pr(>|t|)
(Intercept)  2.060e+00  5.933e-02    34.73   <2e-16 ***
X            4.928e-01  6.607e-03    74.58   <2e-16 ***
I(X^2)      -1.471e+00  7.240e-04 -2031.15   <2e-16 ***
I(X^3)       8.500e-01  3.753e-05 22649.31   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.021 on 846 degrees of freedom
Multiple R-squared:      1,     Adjusted R-squared:      1
F-statistic: 2.323e+09 on 3 and 846 DF,  p-value: < 2.2e-16

>
```

Figure 79: Résultats de la régression polynomiale de degré 3.

Les résultats statistiques sont excellents. L'ensemble des coefficients (β_0, ainsi que les termes associés à X, X^2 et X^3) présentent des p-values infiniment petites ($< 2 \times 10^{-16}$). Ils sont donc tous hautement significatifs.

De plus, le coefficient de détermination multiple (R^2) est égal à 1. Cela signifie que notre modèle cubique explique 100% de la variance de la variable réponse, ce qui correspond à un ajustement parfait aux données.

Comme l'illustre la Figure 80, la courbe rouge issue de notre modèle suit très exactement la trajectoire des données observées.

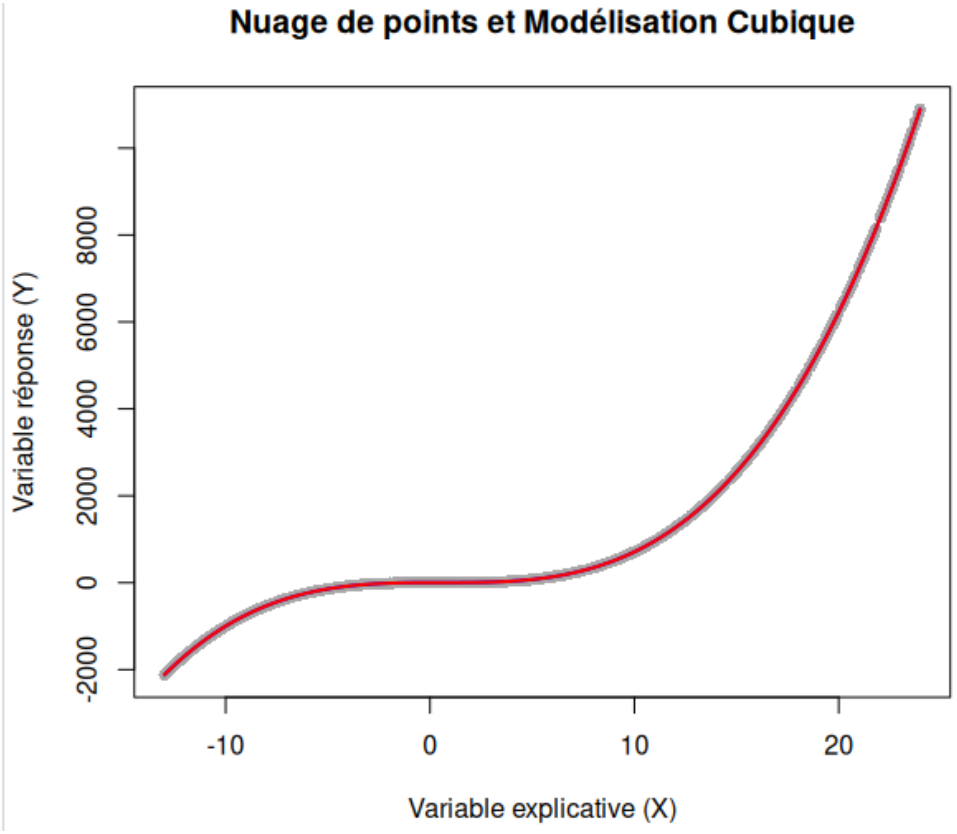


Figure 80: Superposition de la courbe de prédiction (en rouge) sur le nuage de points.

6.3 Vérification des hypothèses sur les résidus

Bien que l'ajustement soit parfait, il convient de vérifier les hypothèses classiques sur les résidus du modèle (normalité et homoscédasticité).

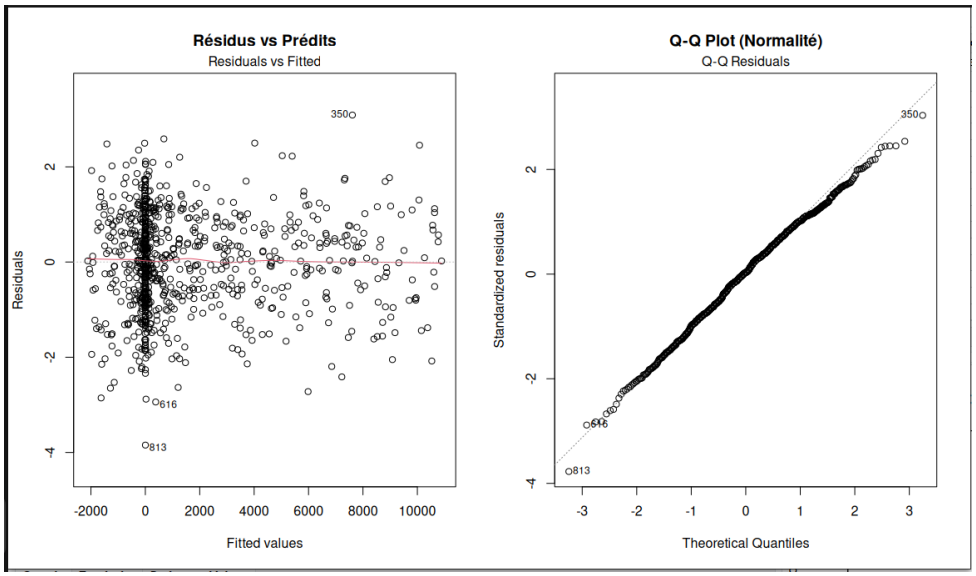


Figure 81: Analyse des résidus : Résidus vs Valeurs prédites et Q-Q plot.

- **Normalité :** Le *Q-Q Plot* montre un alignement remarquable des quantiles empiriques sur la première bissectrice. L'hypothèse de normalité du bruit (ϵ) est validée.
- **Homoscédasticité :** Sur le graphique des résidus en fonction des valeurs prédites, les résidus

sont répartis de manière aléatoire autour de zéro, sans motif particulier en entonnoir. Bien que l'échelle des résidus soit extrêmement faible par rapport aux valeurs prédites (ce qui est logique vu le $R^2 = 1$), l'hypothèse de variance constante est respectée.

En conclusion, la généralisation par l'ajout de variables polynomiales s'est révélée être une stratégie parfaite pour modéliser ces données.